

第五章 非线性方法

2. 人工神经网络

引言

- 贝叶斯分类需要知道样本的概率分布，但估计样本分布有时并不容易
- 直接对数据进行划分的方法：
 - 线性方法：简单、实用、经济，但数据不满足线性可分条件时错误可能大
 - 非线性方法：解决线性不可分问题



年少不听张学友，
听懂已是狱中人。

[张学友演唱会抓了多少逃犯了?46名!看看歌神对这一数字怎么说](#)



2018年10月3日 - 张学友,四大天王中的歌神,不过随着无数逃犯在张学友演唱会上被抓,张学友现在又有了另外一个称号:"逃犯克..."

● 半日娱乐 - 百度快照

[“歌神”张学友是如何成为“逃犯克星”的?](#)



2019年1月12日 - 元旦期间,江苏苏州警方在张学友举行演唱会的3天时间里,抓获22名在逃犯。”歌迷感叹 听说已有将近60个在逃...

● 新民晚报 - 百度快照

天网系统

“准确锁定、捕捉到他们的，是‘天网工程’人脸识别系统，” 南湖公安分局技术与数据服务中心综合管理室主任沈月光介绍说。


“演唱会在正对着检票口的地方增设了几个摄像头，能够对进出检票口所有人员姓名、身份证号、穿着、相貌等进行精确识别把控，它在非常短的时间内便可将数据库筛选一遍。”

.....




神经元

- 神经元（neuron）：
细胞体（cell）、树突（dendrite）、
轴突（axon）、突触（synapses）
- 神经元的作用：加工、传递信息
（电脉冲）
- 神经系统：神经网络：大量神经元的
复杂连接
- 通过大量简单单元的广泛、复杂的
连接而实现各种智能活动。




神经细胞




Purkinje cells



Hippocampus



Retinal ganglion cells



<http://www.cell.com/pictureshow/brainbow>

人工神经网络

Artificial Neural Network

- 自然神经网络的某种模型（数学模型）
- 两路研究方向
 - 探索智能活动机理（类脑）
 - 建立可用的高级机器（AI）
- 简史：
 - 始于1940～1950年代，以Perceptron为代表
 - 1960～1970年代几乎中止研究（AI、符号主义、ES大发展）
 - 1980年代 重掀热潮、达到顶峰
 - 1990年代 趋于平稳，理论进展不大、多应用（混合系统）
统计学习理论与支持向量机兴起。
 - 2010年代，伴随着大数据热潮，以深度学习(deep learning)之名卷土重来

（人工）神经网络的基本结构

大量简单的计算单元（**结点**）以某种形式相连接，形成一个**网络**，其中的某些因素，如连接强度（**权值**）、结点计算特性甚至网络结构等，可依某种规则随外部数据进行适当的调整（**学习**），最终实现某种功能。

- 三个要素：
 - 神经元的计算特性（传递函数）
 - 网络的结构（连接形式）
 - 学习规则
- 三要素的不同形成了各种各样的神经网络模型

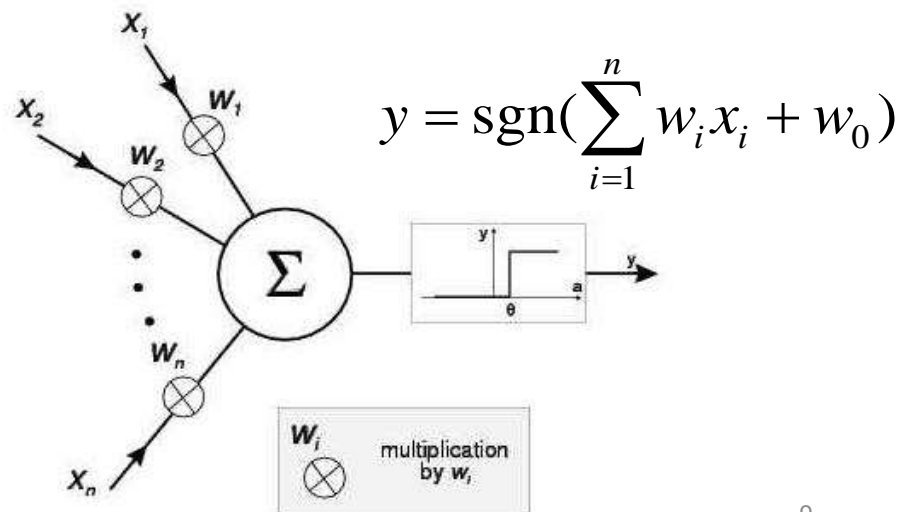

神经网络的基本分类

- 基本可分为三大类：

- 前馈网络 以Multi-layer Perceptron (MLP)为代表
- 反馈网络 以Hopfield网为代表
- 自组织网络（竞争学习网络） 以SOM为代表

- 基本的神经元模型

McCulloch-Pitts Model (1943)
(Threshold Logic Unit - TLU)


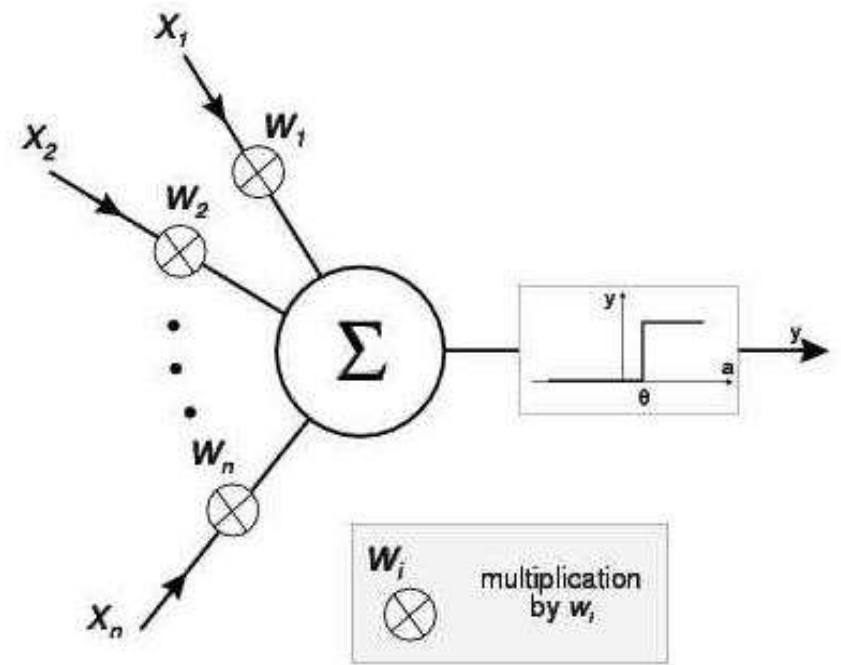


感知器 Perceptron

- Rosenblatt于1950s末提出。



$$y = f_n \left(\sum_{i=1}^n w_i x_i - w_0 \right)$$

$$y = \begin{cases} +1 & \Rightarrow \text{class } A \\ 0 & \Rightarrow \text{class } B \end{cases}$$




多层感知器

- 当两类线性可分时，此算法收敛
- 问题：Minsky等发现并证明(1969)，感知器只能解决一阶谓词逻辑问题，不能解决高阶问题，如不能解决XOR问题。
- 出路：多个感知器结点结合，引入隐节点，如右图的结构可实现XOR。
- ----- 多层感知器




(a) 感知器模型




(b) 输入空间中的两个区域

多层神经网络



$$y = f(W_3 f(W_2 f(W_1 X)))$$

W_i 是权重矩阵 如何求解？



梯度下降法

最小化损失函数：

$$J(Q) = \frac{1}{2} \sum_{i=1}^n (y^{(i)} - f_Q(\mathbf{x}^{(i)}))^2$$

对模型中任意参数迭代更新：


$$w(t) = w(t-1) + \Delta w$$

$$\Delta w = -\alpha * \frac{\partial J}{\partial w} \quad \text{其中 } \alpha \text{ 为学习率}$$

问题：当模型复杂时，如何求解 $\frac{\partial J}{\partial w}$ ？

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$



$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$


$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$

$$h_2 = y - z \quad \frac{\partial h_2}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$



$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$

$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$

$$h_2 = y - z \quad \frac{\partial h_1}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$


给定初值:

$$(x, y, z) = [-1, 3, 2]$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$



$$(x, y, z) = [-1, 3, 2]$$

$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$

$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$


$$h_2 = y - z \quad \frac{\partial h_2}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$

$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$



$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$

$$h_2 = y - z \quad \frac{\partial h_1}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$


$$(x, y, z) = [-1, 3, 2]$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$

$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$



$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$

$$h_2 = y - z \quad \frac{\partial h_2}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$


$$(x, y, z) = [-1, 3, 2]$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

计算图 (Computational Graph)

$$f = (x + y)(y - z)$$

$$f = h_1 * h_2 \quad \frac{\partial f}{\partial h_1} = h_2 \quad \frac{\partial f}{\partial h_2} = h_1$$



$$h_1 = x + y \quad \frac{\partial h_1}{\partial x} = 1 \quad \frac{\partial h_1}{\partial y} = 1$$

$$h_2 = y - z \quad \frac{\partial h_2}{\partial y} = 1 \quad \frac{\partial h_2}{\partial z} = -1$$


$$(x, y, z) = [-1, 3, 2]$$

目标：求解 $\frac{\partial f}{\partial x}$, $\frac{\partial f}{\partial y}$, $\frac{\partial f}{\partial z}$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$


初值: $x=-2$ $w_0=1$
 $y=1$ $w_1=3$



又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=1$
 $y=1$ $w_1=3$



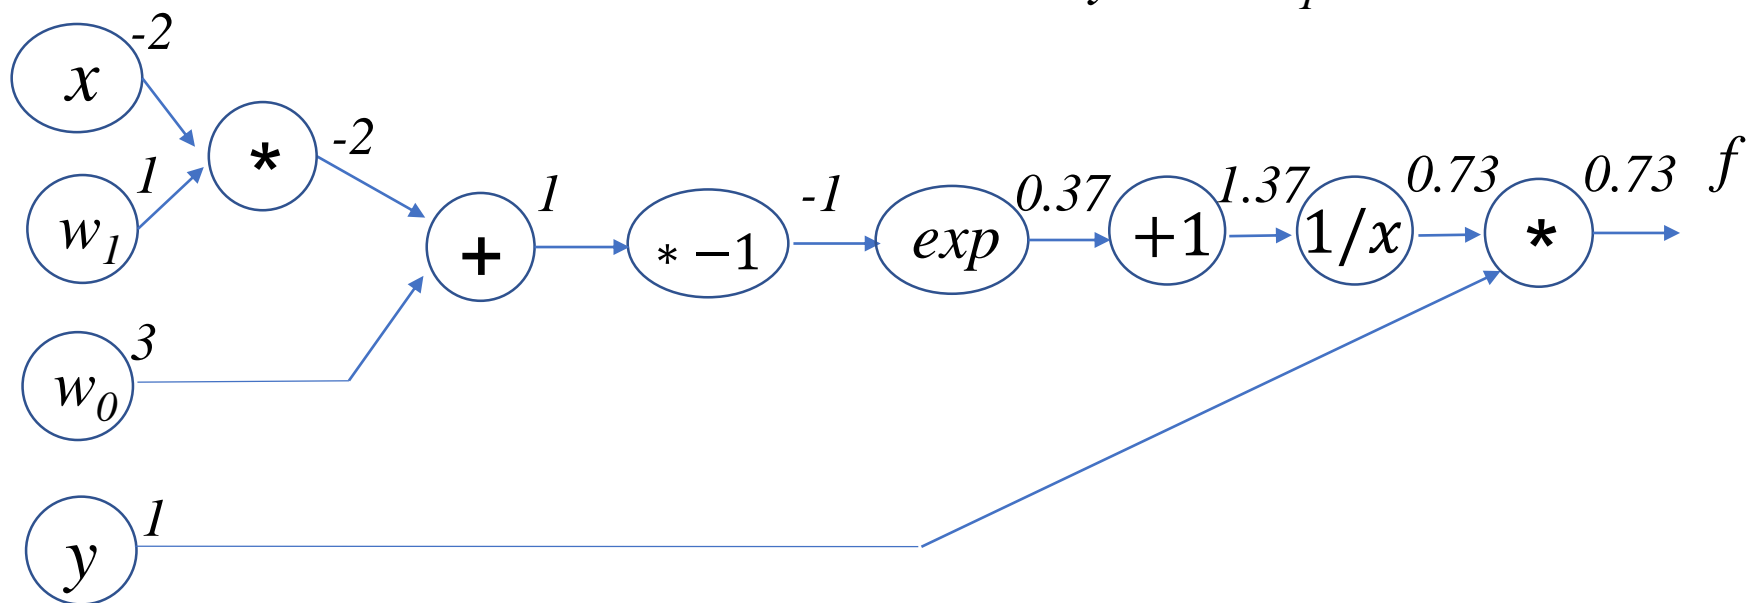
$$f = h_6 * y \quad h_6 = 1/h_5 \quad h_5 = 1 + h_4 \quad h_4 = \exp(h_3)$$

$$h_3 = (-1) * h_2 \quad h_2 = w_0 + h_1 \quad h_1 = x + w_1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

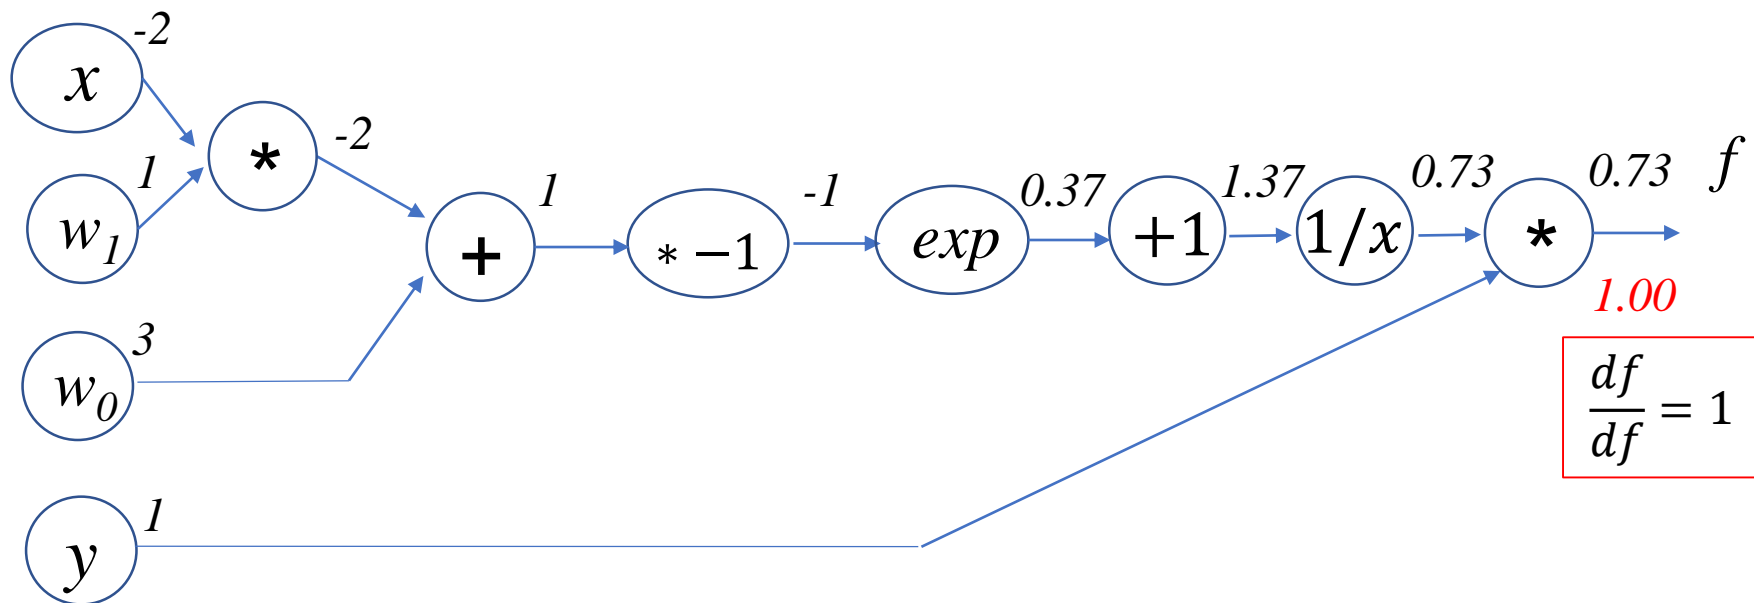
初值: $x=-2$ $w_0=1$
 $y=1$ $w_1=3$



又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x_0 = -2$ $w_0 = 3$ $w_1 = 1$ $y = 1$

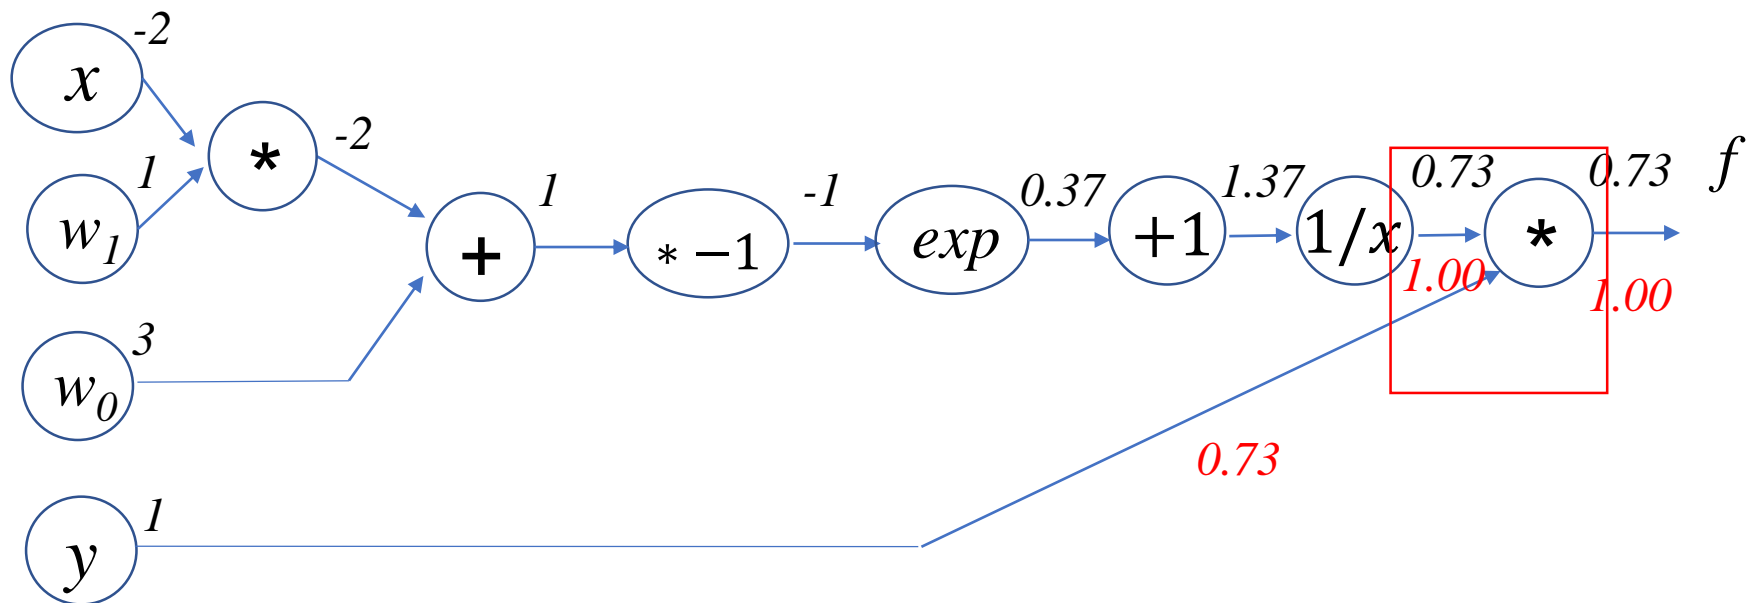


$$\begin{aligned} f(x) = ex &\rightarrow \frac{df}{dx} = ex & f(x) = \frac{1}{x} &\rightarrow \frac{df}{dx} = -\frac{1}{x^2} \\ f(x) = ax &\rightarrow \frac{df}{dx} = a & f(x) = a + x &\rightarrow \frac{df}{dx} = 1 \end{aligned}$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$

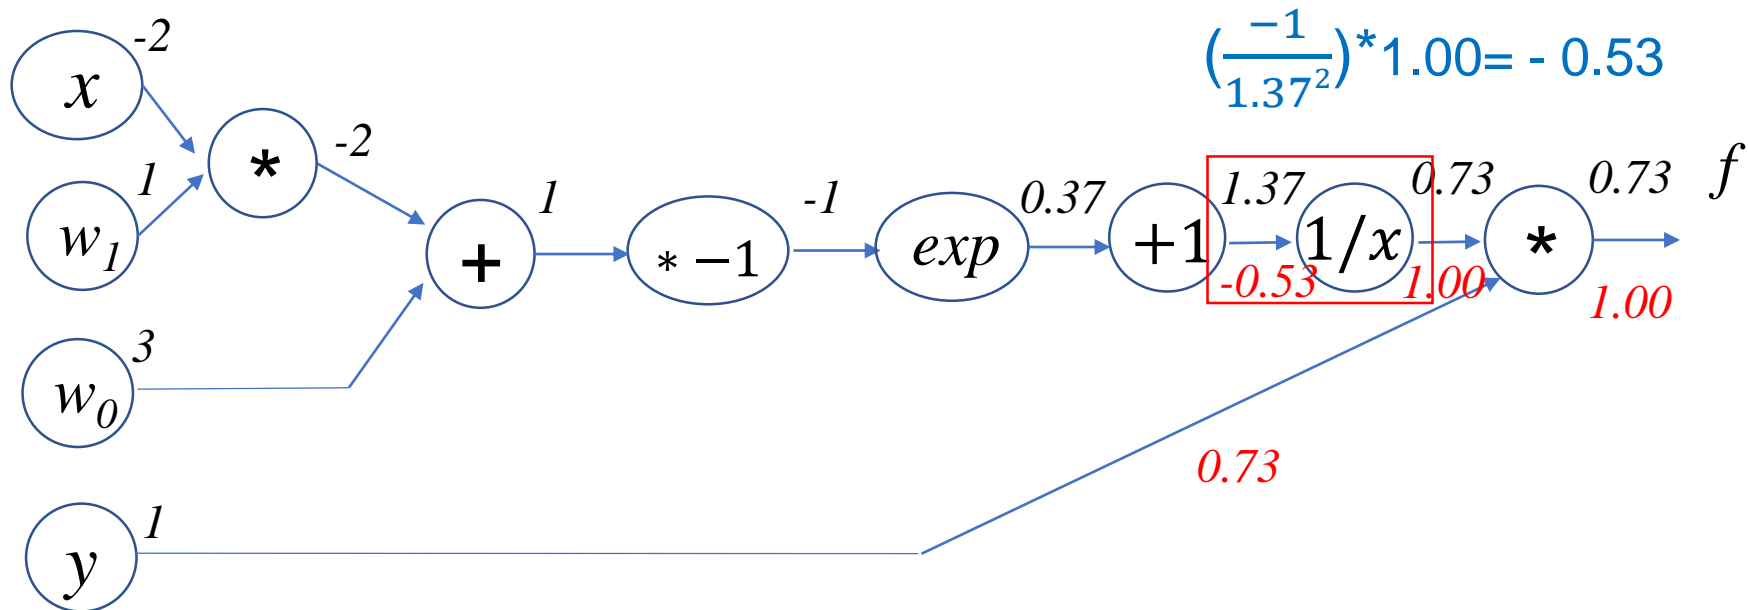
$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$


$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x_0)}}$$

初值: $x_0 = -2$ $w_0 = 3$ $w_1 = 1$ $y = 1$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$

$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$


$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$

$$\exp(-1) * (-0.53) = -0.20$$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$

$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$


$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$

$$(-1)^*(-0.20) = 0.20$$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$

$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$


$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$

$$(1) * (0.20) = 0.20$$



$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$


$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$

又一个例子

$$f = \frac{y}{1 + e^{-(w_0 + w_1 x)}}$$

初值: $x=-2$ $w_0=3$ $w_1=1$ $y=1$




$$f(x) = ex \rightarrow \frac{df}{dx} = ex$$

$$f(x) = ax \rightarrow \frac{df}{dx} = a$$


$$f(x) = \frac{1}{x} \rightarrow \frac{df}{dx} = -\frac{1}{x^2}$$

$$f(x) = a + x \rightarrow \frac{df}{dx} = 1$$


对任意的神经元



对任意的神经元




对任意的神经元



多层感知器与BP算法

(MLP & the Back-Propagation Algorithm)



MLP结构



定义误差损失函数：

$$E = \frac{1}{2} \sum_{k=1}^m (\hat{y}_m - y_m)^2$$

f 为节点的**激活函数**，例如采用Sigmoid函数



$$f(\alpha) = \frac{1}{1 + e^{-(\alpha - \theta)}}$$

BP算法：

LeCun, 1986; Rumelhart, Hinton & Williams, 1986; Parker, 1985

- (1) 权值初始化, $t = 0$ (用小随机数)
- (2) 给出一个训练样本 $x = [x_1, \dots, x_n]^T \in R^n$ 和期望输出 $D = [y_1, \dots, y_m]^T \in R^m$
- (3) 计算在 x 输入下的实际输出 $Y = [y_1, \dots, y_m]^T$
- (4) 从输出层开始, 调整权值, 对第 l 层, 有

$$w_{ij}^l(t+1) = w_{ij}^l(t) - \eta \delta_j^l x_i^{l-1}, \quad j = 1, \dots, n_l, \quad i = 1, \dots, n_{l-1}$$

其中其中 η 为学习步长, δ_j^l 计算如下:

$$\text{对输出层: } \delta_j^l = f'(z_j^l)(\hat{y}_j - y_j), \quad j = 1, \dots, m$$

$$\text{对中间层: } \delta_j^l = f'(z_j^l) \sum_{k=l+1}^{n_{l+1}} \delta_k^{l+1} w_{jk}^{l+1}(t), \quad j = 1, \dots, n_l$$

- (5) 重新计算输出, 考查误差指标 (或其它终止条件)
如达到终止条件则终止, 否则置 $t = t+1$, 转 (2)。

说明：

- 算法可能收敛于局部极小点（梯度算法）
- 与初值、步长等的选择有关
- 更与网络结构（结点数目）有关


多凭经验或试验选择

改进：如步长时变，网络结点可剪裁，等等。

关于激活函数


- Sigmoid函数: $f(z) = \frac{1}{(1 + e^{-z})}$
- 双曲正切函数 (hyperbolic tangent, Tanh) :

$$f(z) = \frac{(e^z - e^{-z})}{(e^z + e^{-z})} = \frac{2}{(1 + e^{-2z})} - 1$$




- Rectified Linear Unit (ReLU):

$$f(z) = \max(0, z)$$




- Leaky-ReLU:

$$f(z) = \begin{cases} z & (z > 0) \\ az & (z < 0) \end{cases}$$



- Exponential Linear Units (ELU)

$$f(z) = \begin{cases} z & \text{if } z > 0 \\ a(e^z - 1) & \text{if } z \leq 0 \end{cases}$$




- Maxout:

$$f(z) = \max(w_1^T z + b_1, w_2^T z + b_2)$$

ReLU is a good starting point

使用ReLU函数通常有较快的收敛速度



Alex Krizhevsky, ICONIP , (2012)

MLP特性：可以实现复杂的非线性映射关系

用于分类：

- 两层网（一个隐层）可实现空间内任意的凸形成区域的划分。
- 三层网（两个隐层）可实现任意形状（连续或不连续）区域划分。

---- 属存在性性质，问题是如何找到这样的网络结构？




FIGURE 6.2. A 2-4-1 network (with bias) along with the response functions at different units; each hidden output unit has sigmoidal activation function $f(\cdot)$. In the case shown, the hidden unit outputs are paired in opposition thereby producing a “bump” at the output unit. Given a sufficiently large number of hidden units, any continuous function from input to output can be approximated arbitrarily well by such a network. From: Richard O. Duda, Peter E. Hart, and David G. Stork, *Pattern Classification*. Copyright © 2001 by John Wiley & Sons, Inc.

用多层感知器网络实现模式识别

- 输入 x —— 样本特征向量（必要时归一化）
- 输出 Y —— 类别编码
- 常用输出编码：
 - 1-of-C编码：
 - c 类则 c 个输出结点，第 i 类则 $y_i = 1$ 其它 $y_j = 0 \quad i \neq j$
 - 两类：一个输出结点，0、1各代表一类。
 - 也可用 c 个网络解决 c 类问题，每个网络只分一类（是与否）。

其它应用： 函数拟合、时间序列预测、数据压缩，

神经网络研究的“教父” ---加拿大多伦多大学Geoffrey E. Hinton教授



坚持人工神经网络研究40余年
深度学习的开创者

<http://www.cs.toronto.edu/~hinton/>

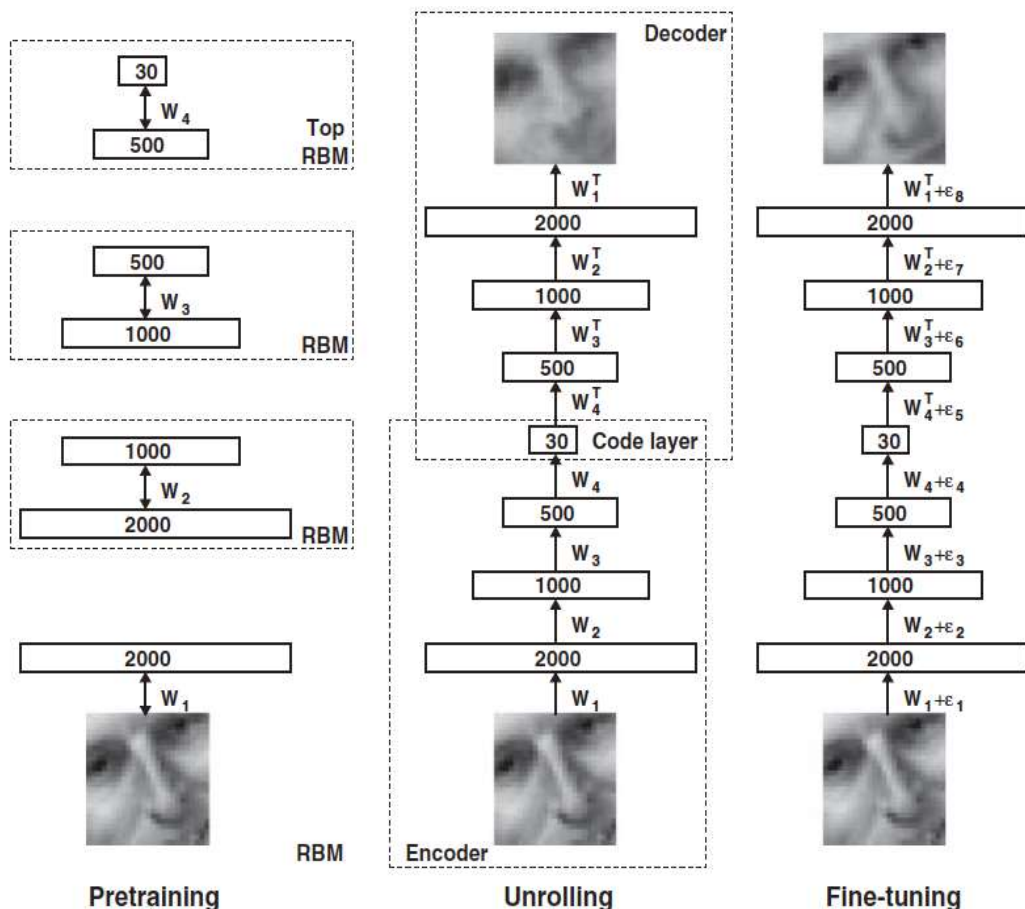
深度神经网络的特征表示

Reducing the Dimensionality of Data with Neural Networks

G. E. Hinton* and R. R. Salakhutdinov

2006 Science

“Autoencoder”



RBM: 受限玻尔兹曼机
(Restricted Boltzmann Machine)

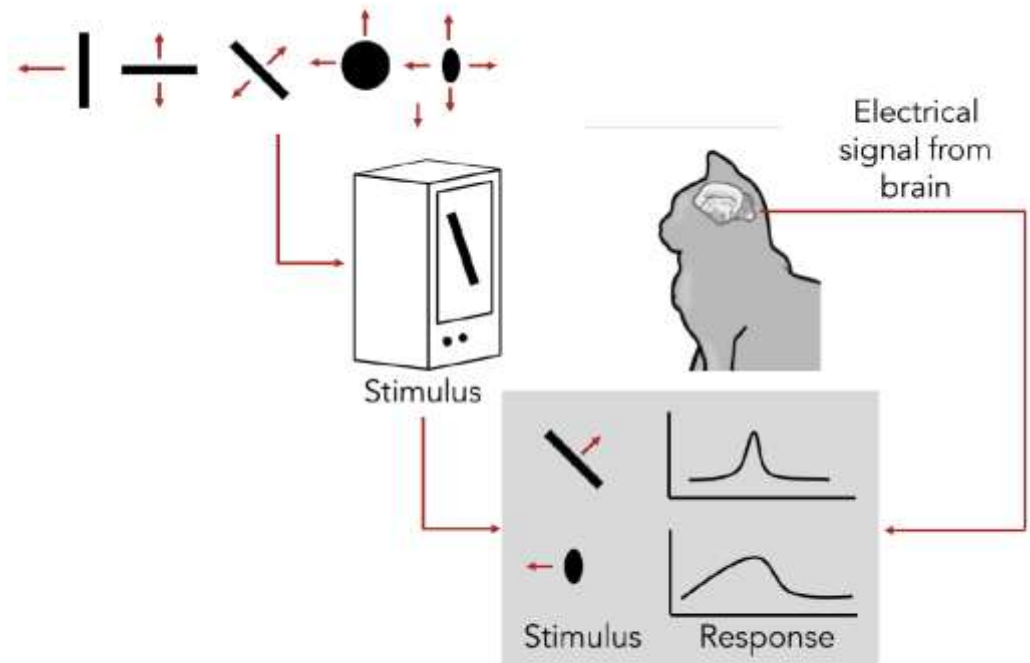
RBM不区分前向和反向，可理解为编码和解码过程

视觉神经系统模型



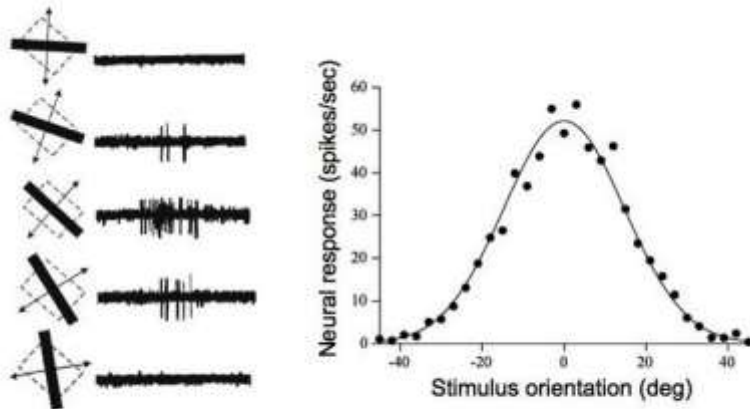
Hubel & Wiesel,

1981 Nobel Prize in Physiology or Medicine




slide from Fei-Dei Li, Justin Johnson, Serena Yeung, **cs231n Stanford**


[Cat image](#) by CNX OpenStax is licensed under CC BY 4.0; changes made



Hubel & Wiesel





featural hierarchy



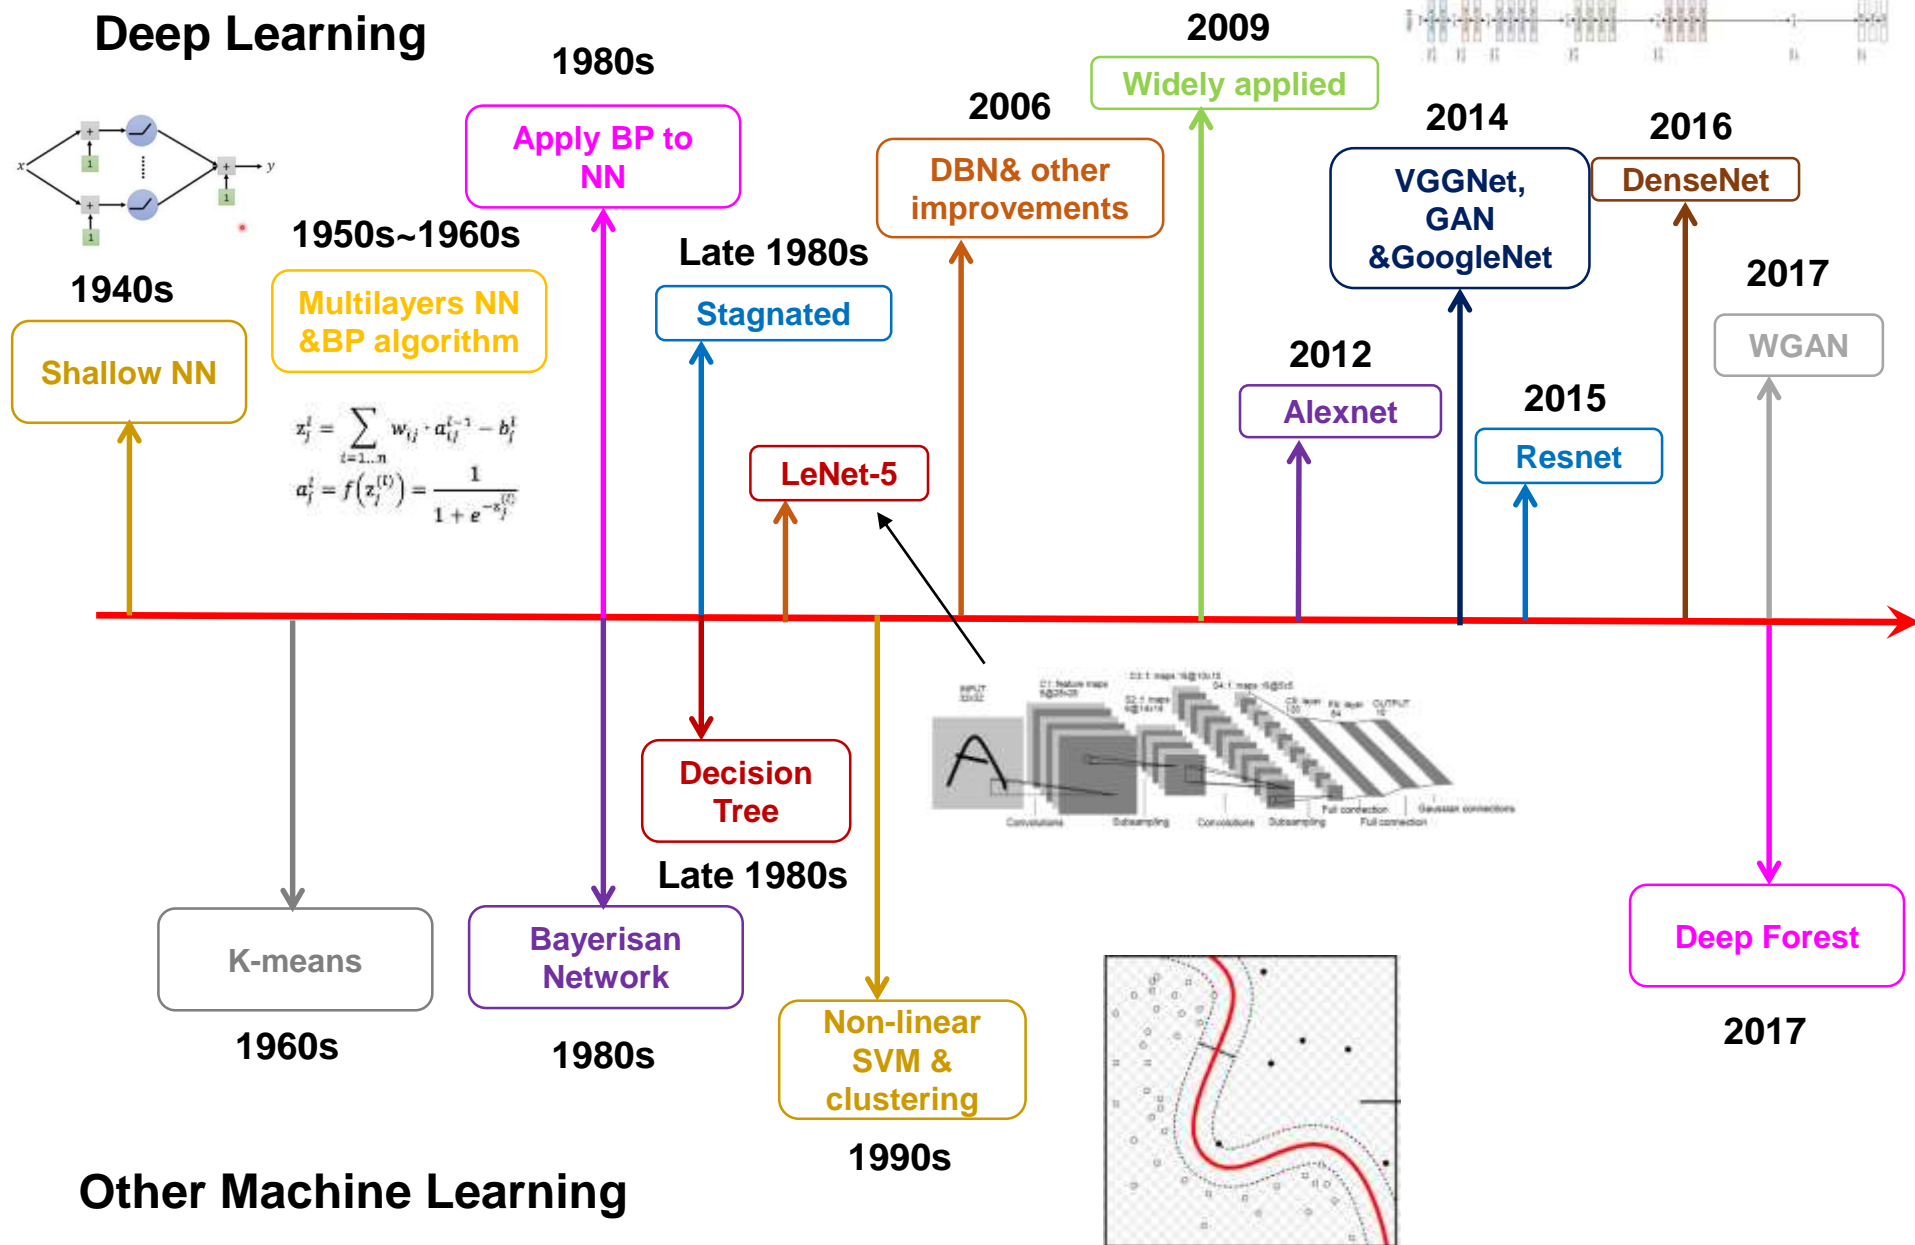
层次化的特征表示


Deep neural networks learn hierarchical feature representations





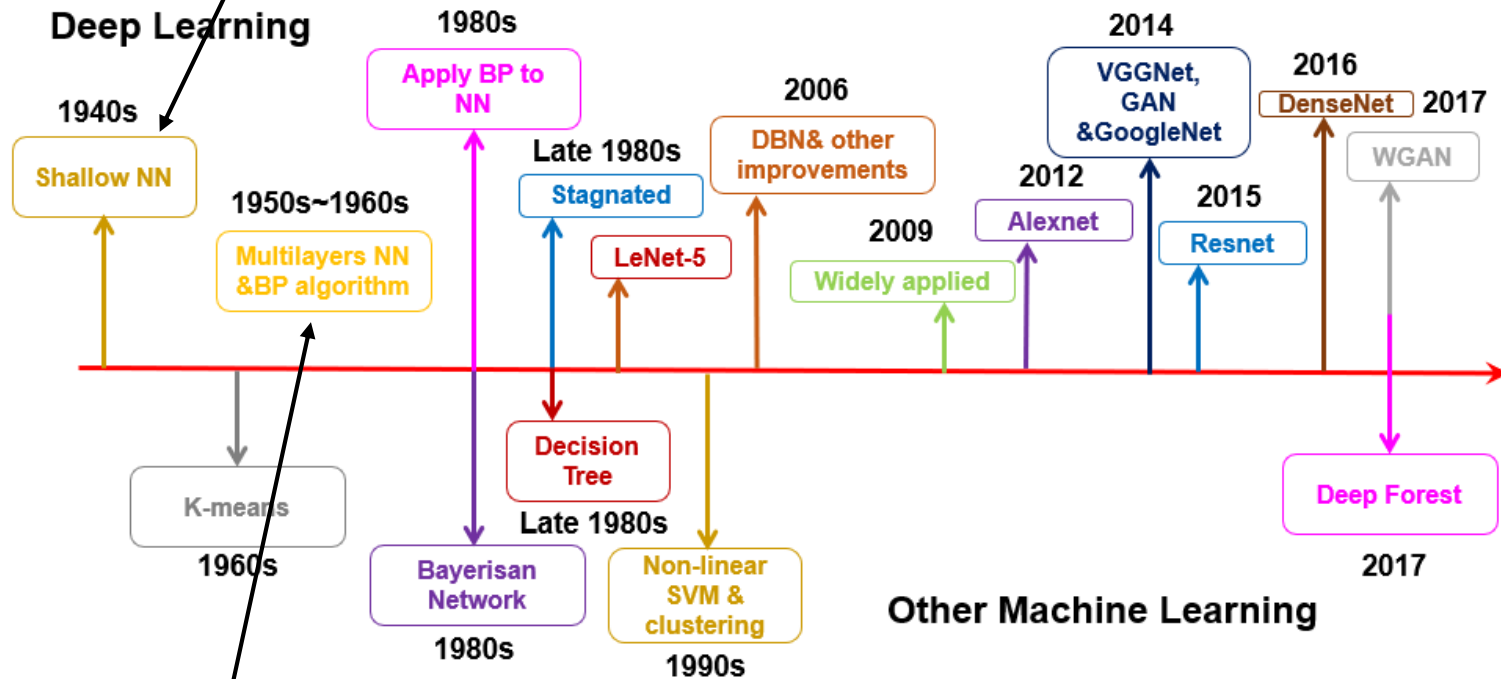
Deep Learning发展



Deep Learning



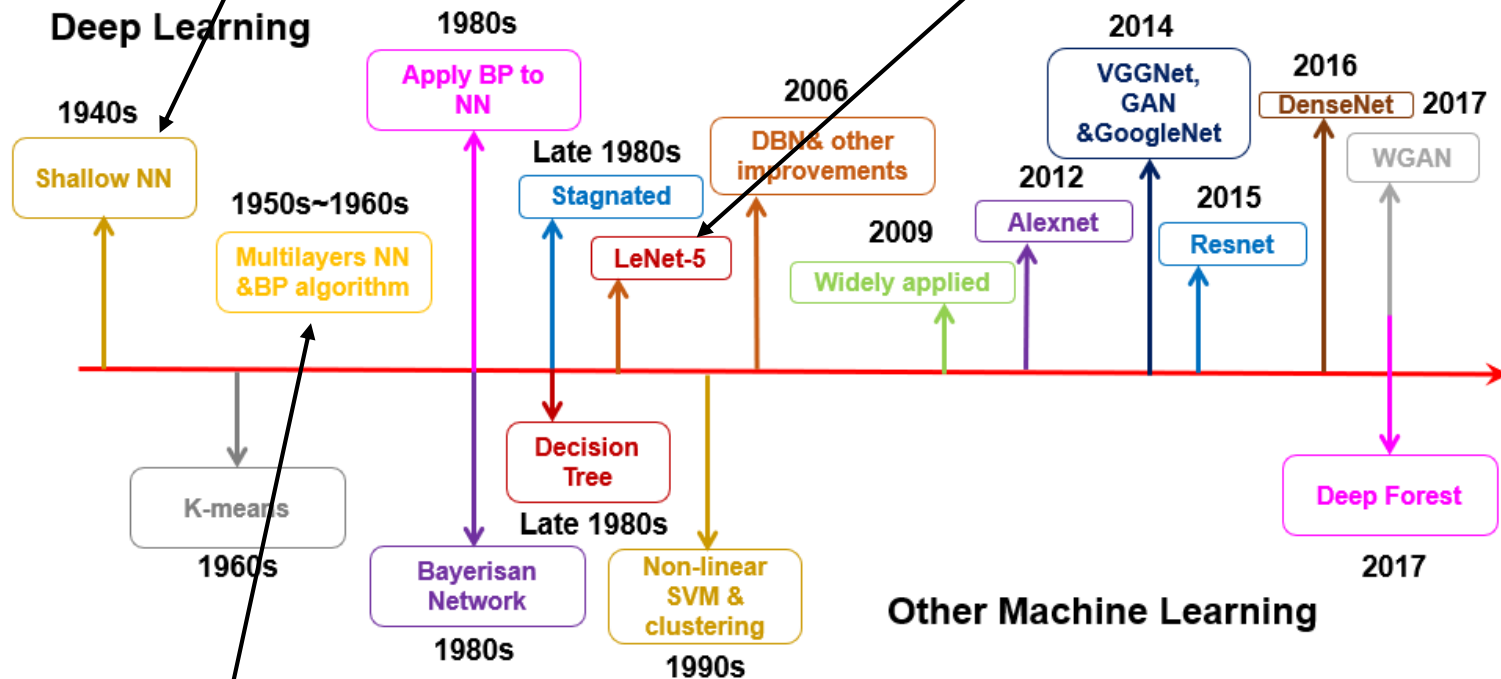


Deep Learning









Deep Learning

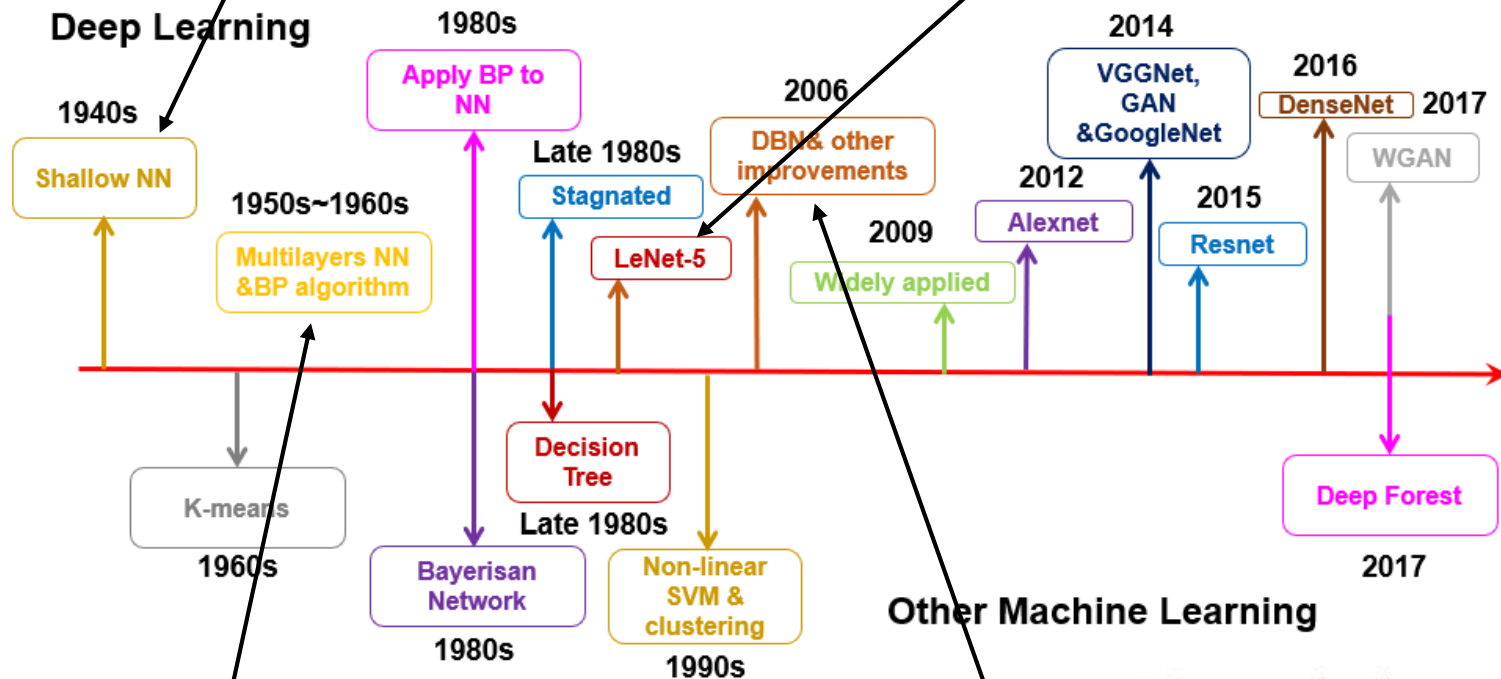


Other Machine Learning








Deep Learning

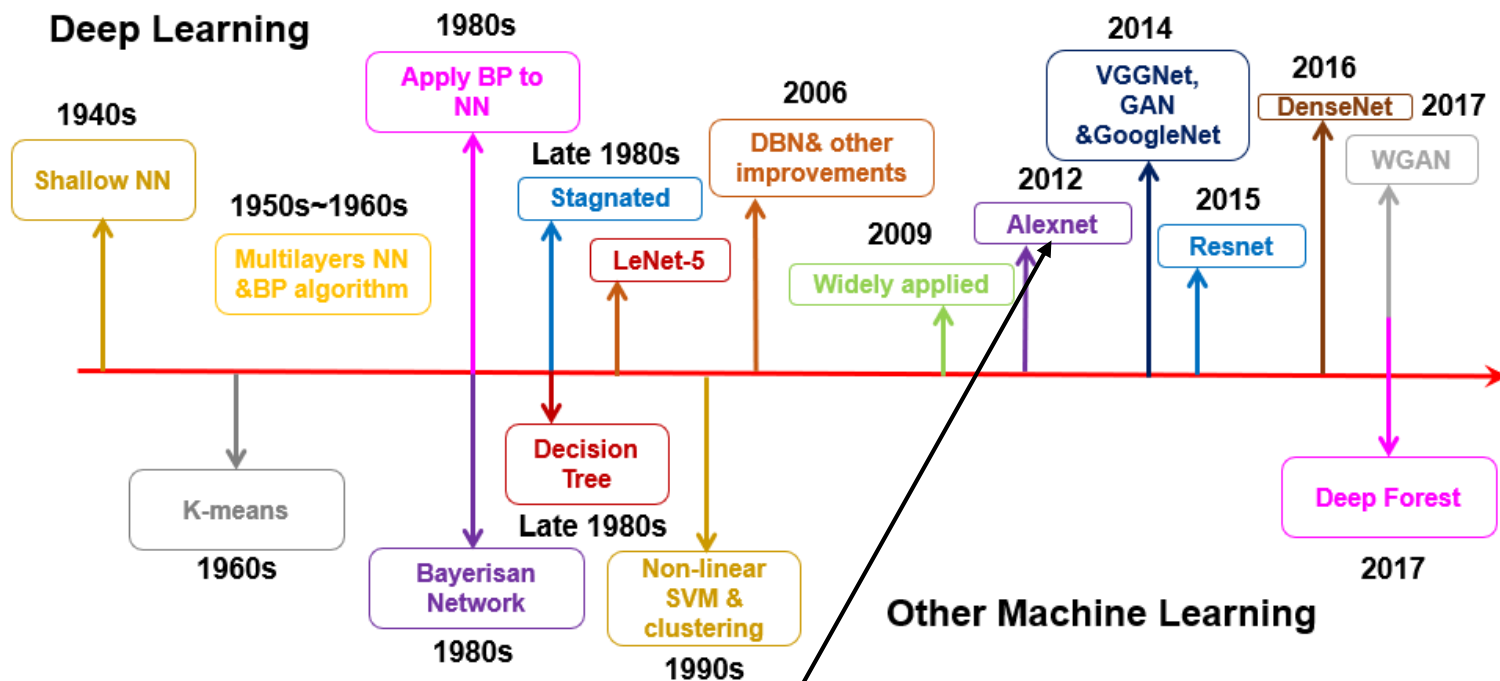


Other Machine Learning


Deep Belief Network (DBN)



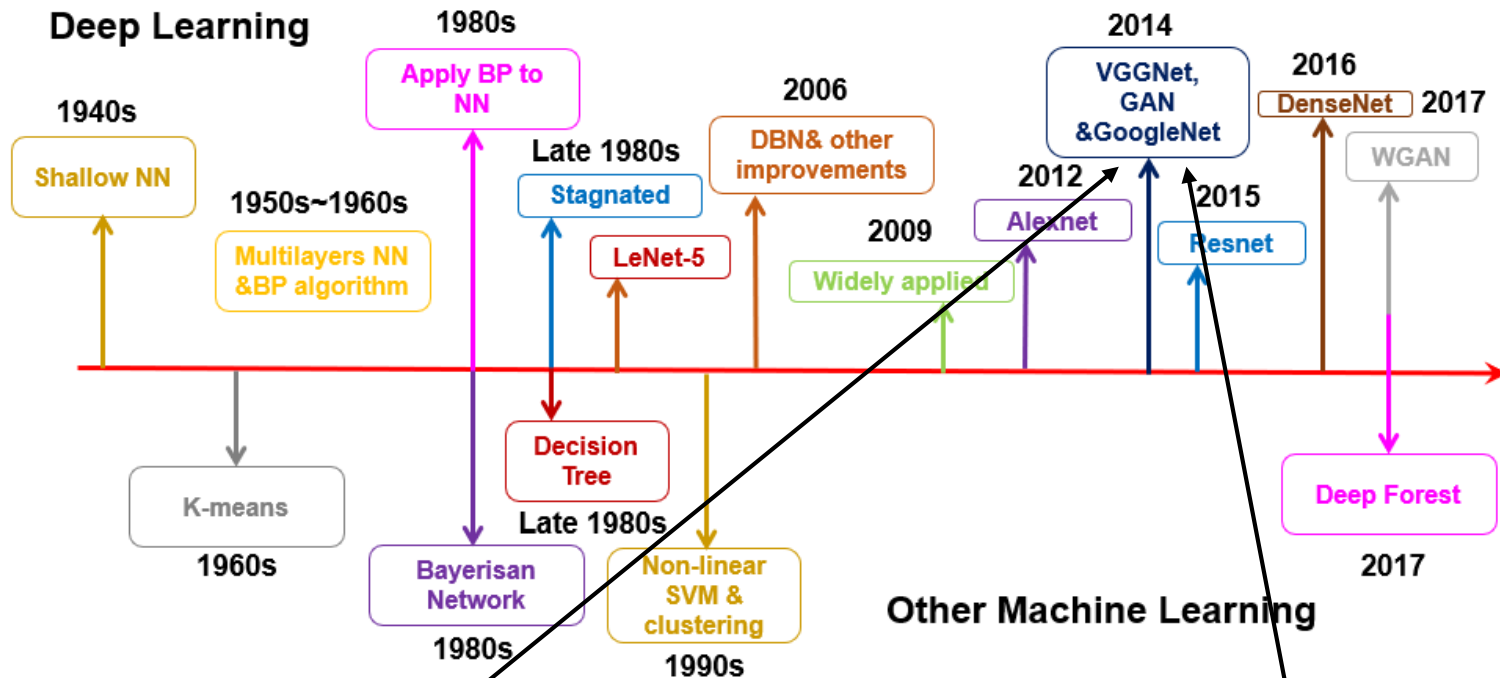
Deep Learning



AlexNet




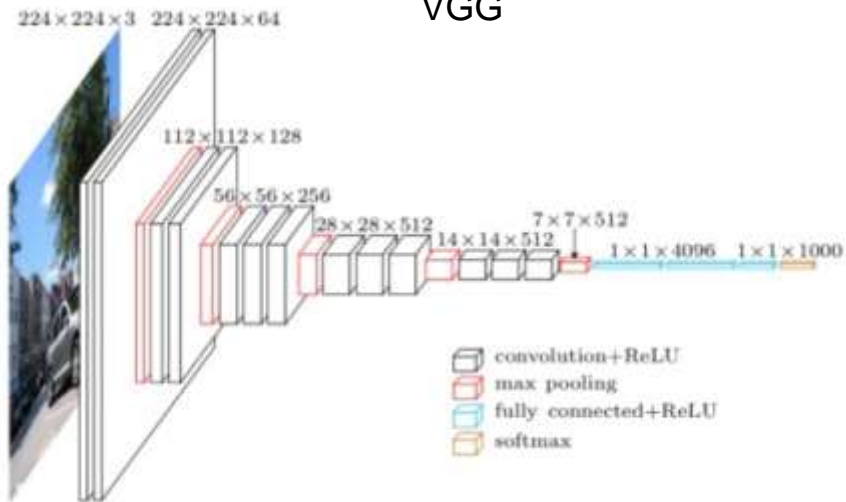
Deep Learning



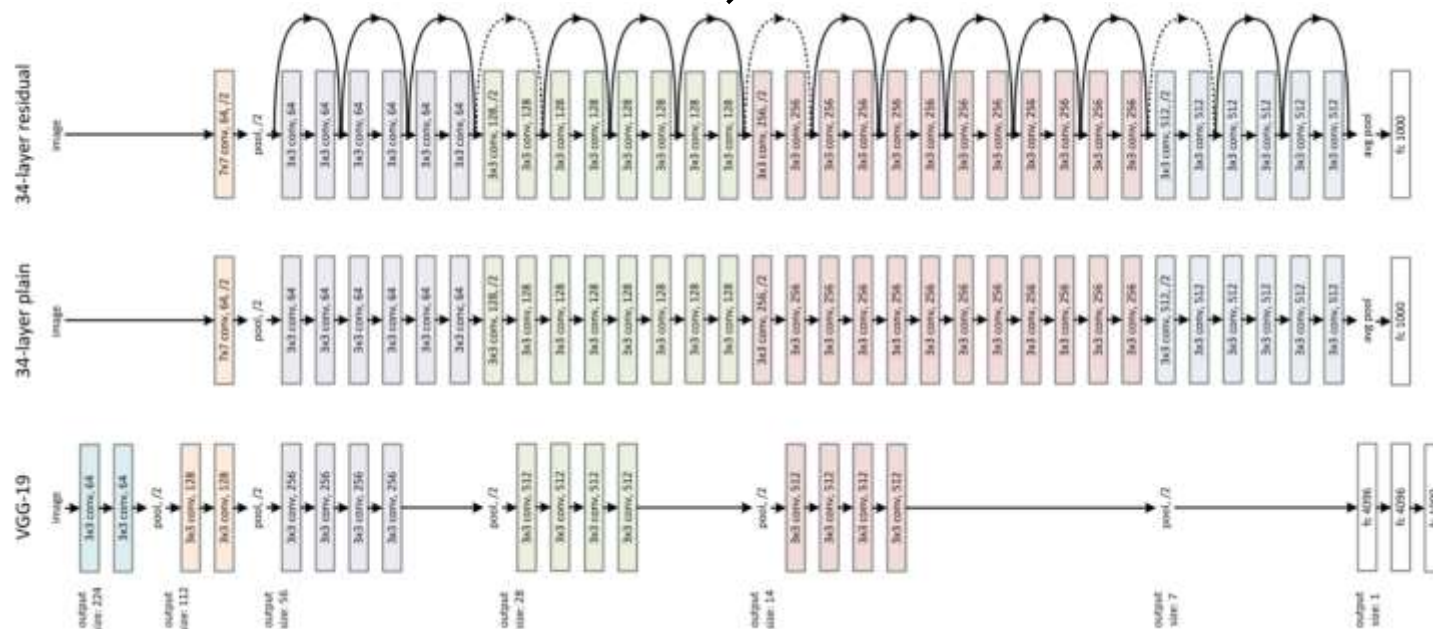
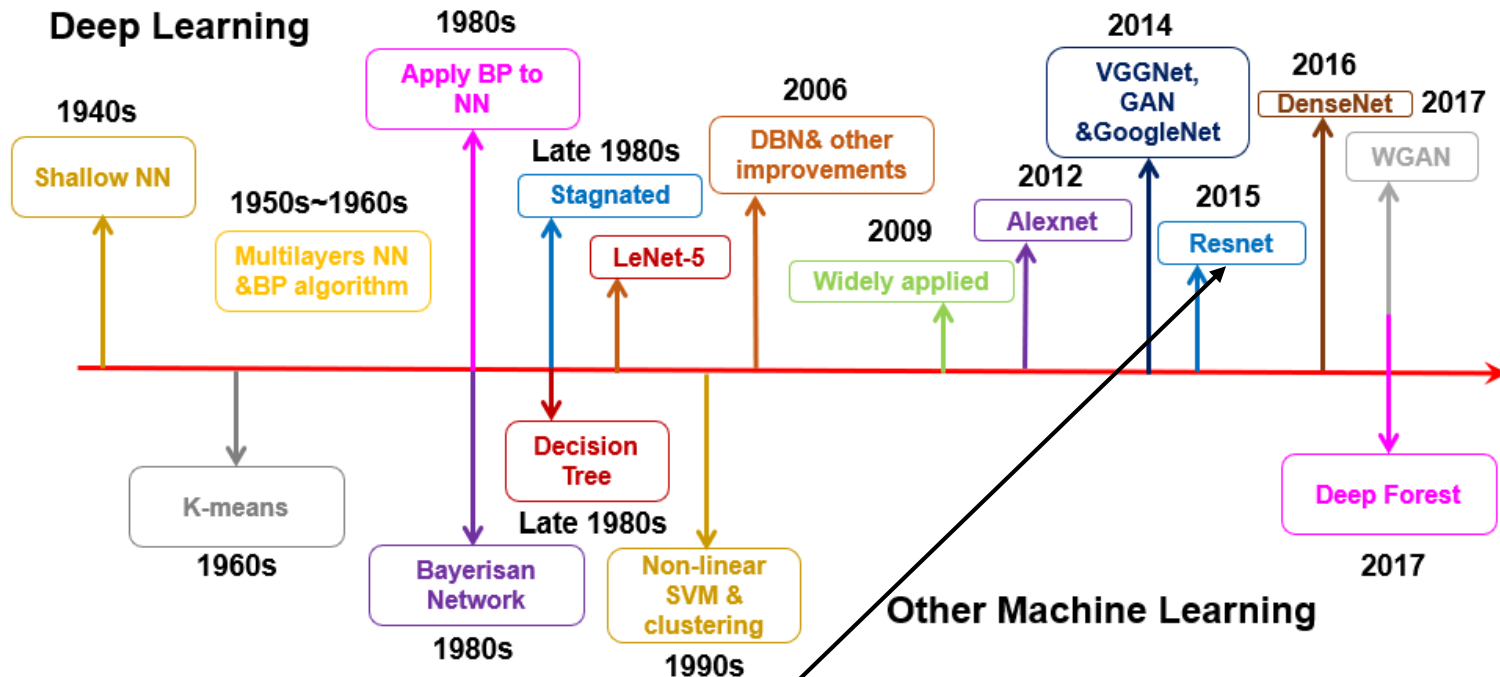
Other Machine Learning

VGG


GoogleNet



Deep Learning




Deep Learning v.s. Classical methods



卷积神经网络


- 卷积神经网络（Convolutional Neural Network, CNN）是一种前馈神经网络，近年来被大量应用于计算机视觉、自然语言处理等领域。
- CNN的研究始于二十世纪末，时间延迟网络和LeNet-5是最早出现的卷积神经网络，近年来卷积神经网络的规模逐渐增大，例如AlphaGo有超过40层的卷积神经网络。



LeNet-5结构, LeCun, et al. *Proceedings of the IEEE* (1998).

卷积神经网络

- 卷积神经网络被广泛使用在图像分类、物体识别等图像领域任务中；
- 卷积神经网络使用卷积核(kernel)捕捉图像特征；
- 卷积核可以自底向上，层级提取图像特征，如下图：



Convolutional neuron networks (CNN)

- LeNet: convolutional network designed for handwritten and machine-printed character recognition


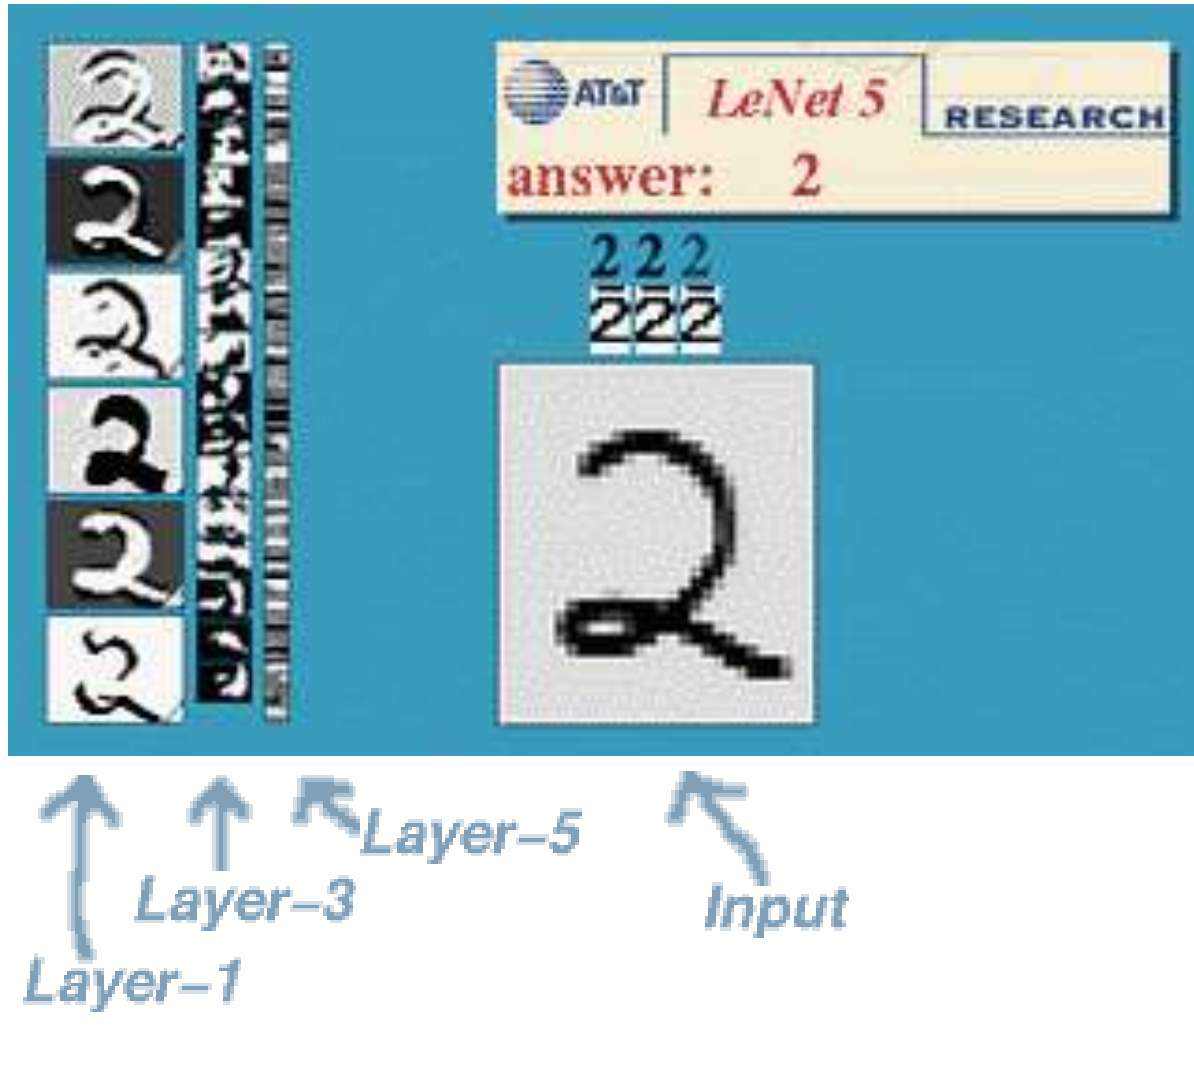


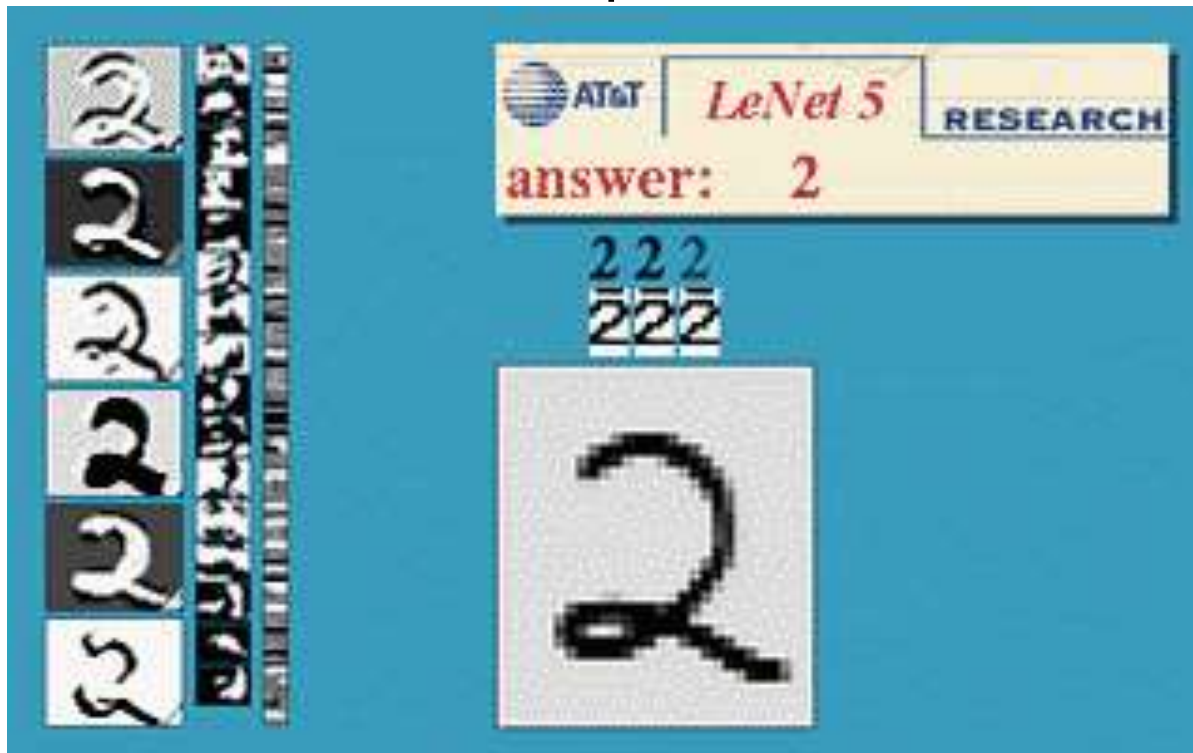
Fig. 2. Architecture of LeNet-5, a Convolutional Neural Network, here for digits recognition. Each plane is a feature map, i.e. a set of units whose weights are constrained to be identical.

LeCun, Y., Bottou, L., Bengio, Y., and Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*, 86(11), 2278–2324.

LeNet: convolutional network designed for handwritten and machine-printed character recognition




LeNet: convolutional network designed for handwritten and machine-printed character recognition




端到端 (end-to-end)

‘Classical’ Machine Learning

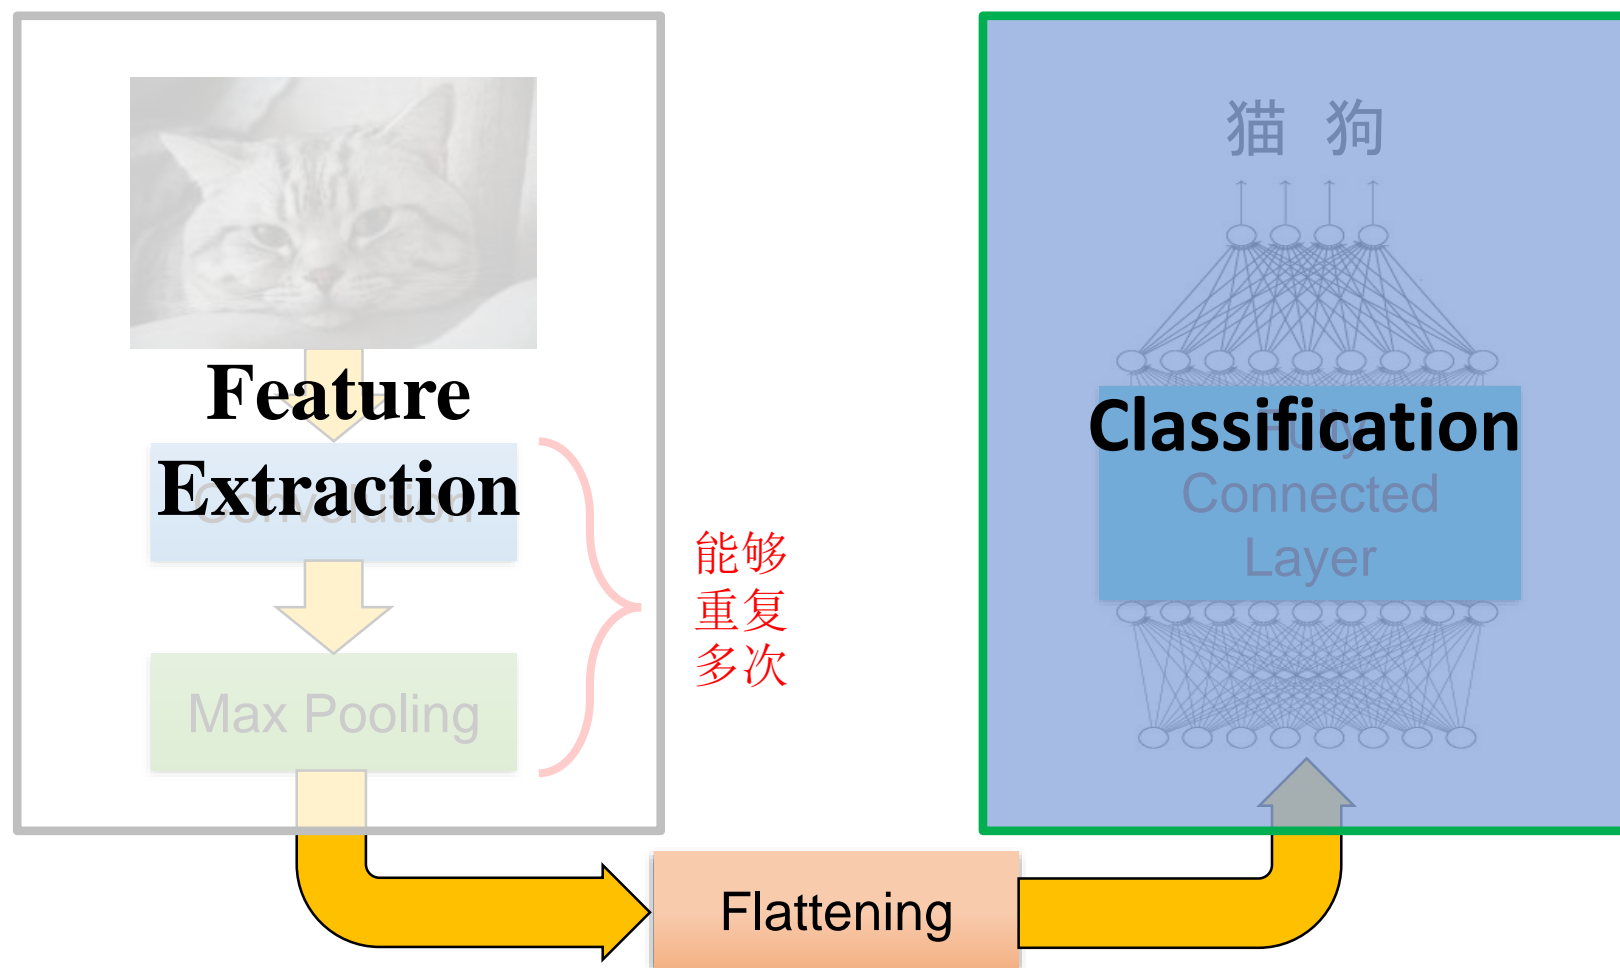


Deep Learning




图片来源: <https://towardsdatascience.com/why-deep-learning-is-needed-over-traditional-machine-learning-1b6a99177063>

CNN在图像识别中的应用





卷积层（Convolutional layer）

- 卷积层是卷积神经网络的核心部分，一个卷积层通常含有数个卷积核（filters）来执行卷积操作。



卷积层

- CNN中常用Padding和Strides来控制输出图像的大小。
 - Padding: 用额外的像素点来填充边缘, 使得输出大小等于输入大小。
 - Strides: 用来调整卷积的步长, 产生不同尺寸的输出。



左: Padding, 右: strides=2, Dumoulin, et al. arXiv:1603.07285(2016).

卷积层

- 卷积层通过卷积操作来捕获filters关注的信息。

1	0	0	0	0	1
0	1	0	0	1	0
1	0	0	0	0	1
1	0	1	0	1	1
0	0	0	0	1	1
0	0	1	0	1	1

6X6图像

1	0	0
0	1	0
1	0	0

0	0	1
0	0	1
0	0	1

⋮ ⋮

每个filter检测3X3的pattern。

卷积层

- 卷积层通过卷积操作来捕获filters关注的信息。

Filter1

1	0	0
0	1	0
1	0	0

1	0	0	0	0	1
0	1	0	0	1	0
1	0	0	0	0	1
1	0	1	0	1	1
0	0	0	0	1	1
0	0	1	0	1	1

6X6图像



3	0	0	1
1	1	1	0
1	1	0	1
1	0	2	1

卷积层


- 卷积层通过卷积操作来捕获filters关注的信息。

Filter2

0	0	1
0	0	1
0	0	1

1	0	0	0	0	1
0	1	0	0	1	0
1	0	0	0	0	1
1	0	1	0	1	1
0	0	0	0	1	1
0	0	1	0	1	1


6X6图像



2个4X4的图像构成了
一个2X4X4的图像

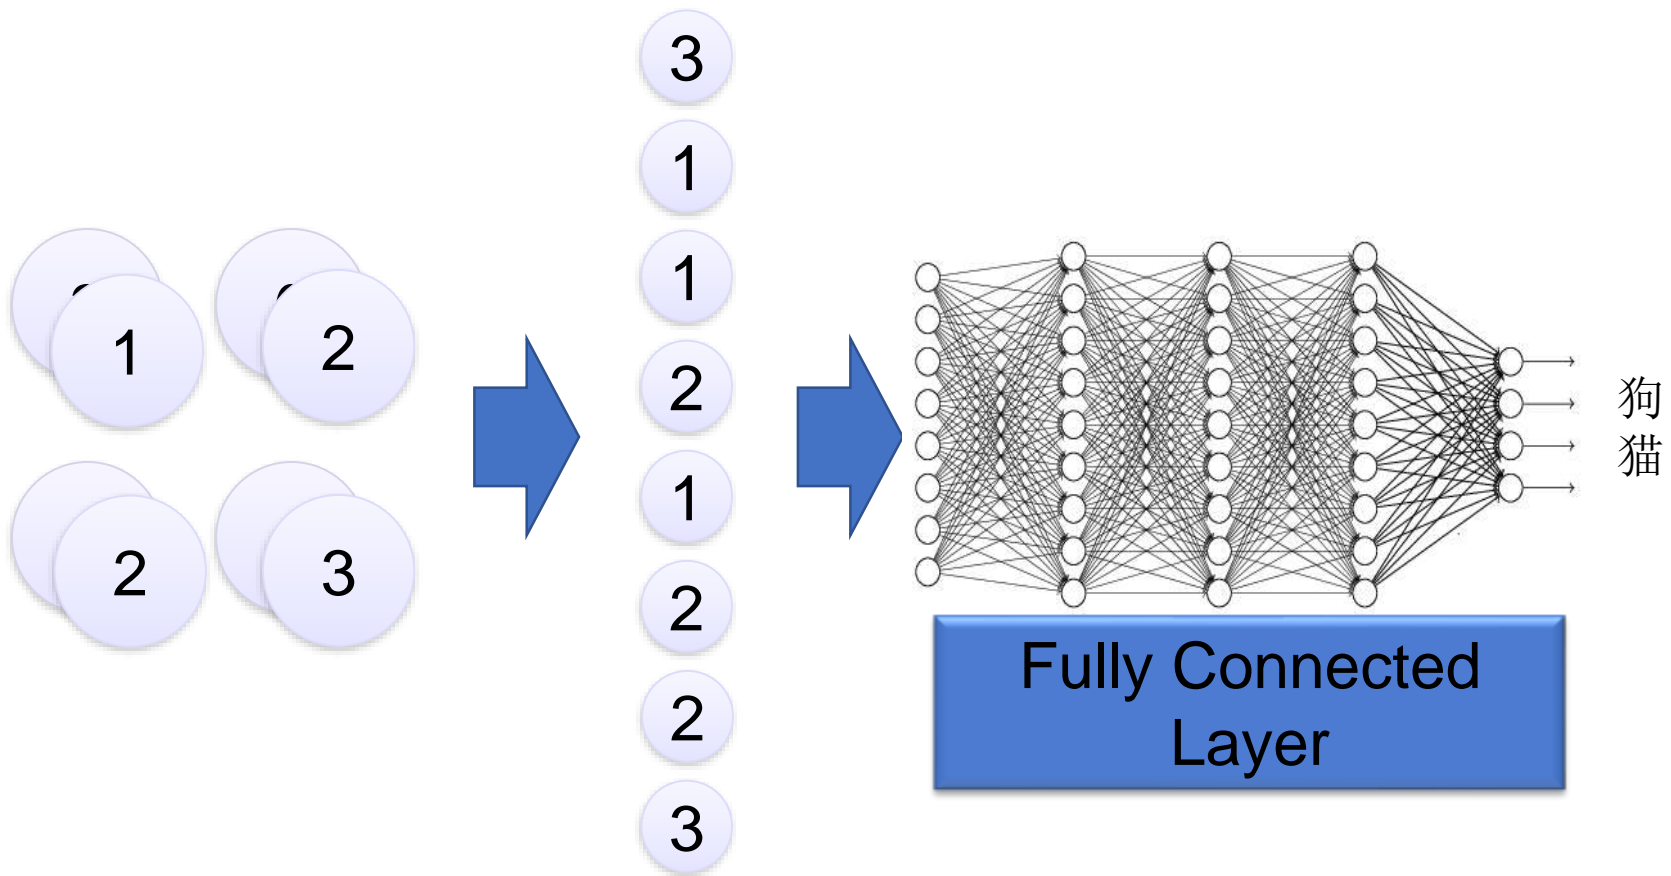
池化层 (Pooling layer)

- 对像素的抽样可以在一定程度上保持原始对象，并且减少描述对象所需要的参数。



对图片进行抽样

Flattening和全连接网络



天网系统

“准确锁定、捕捉到他们的，是‘天网工程’人脸识别系统，” 南湖公安分局技术与数据服务中心综合管理室主任沈月光介绍说。

“演唱会在正对着检票口的地方增设了几个摄像头，能够对进出检票口所有人员姓名、身份证号、穿着、相貌等进行精确识别把控，它在非常短的时间内便可将数据库筛选一遍。”

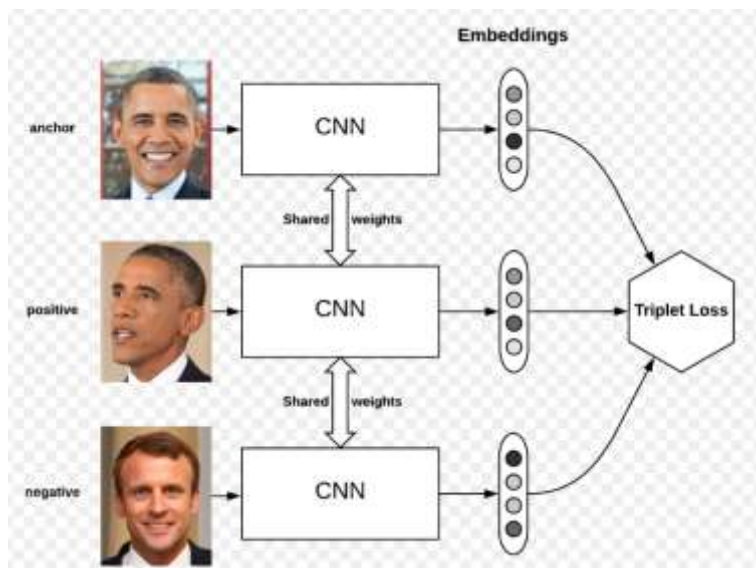
.....




人脸识别技术 - Facenet

- Face embedding + optimize Triplet Loss

利用CNN将照片投影到表示向量空间




- 在表示空间用欧式距离度量不同人脸照片间的相似度



人脸照片相似度矩阵






Person #2




优化Triplet Loss

物体识别技术 – Faster R-CNN

S Ren, CVPR, 2016





不同大小的窗：




循环神经网络

- 循环神经网络(Recurrent Neural Network, RNN)是一类用于处理序列数据的神经网络，它广泛的用于自然语言处理中的语音识别、机器翻译、故障诊断等领域。
- RNN可以将之前的输入“记忆”在神经网络中，从而输出也与之前输入有关，如下图的例子：




循环神经网络

- RNN是包含有循环的网络，可以使用展开计算图的方式表示。
 - x_t : 输入, h_t : 隐藏层, y_t : 输出



循环神经网络

- RNN每一层的计算需要考虑到上一层的影响，假设使用双曲正切激活函数(tanh)的前提下，用RNN来预测词或者字符，其推导过程如下所示。



$$h_t = \tanh(b + Wh_{t-1} + Ux_t)$$

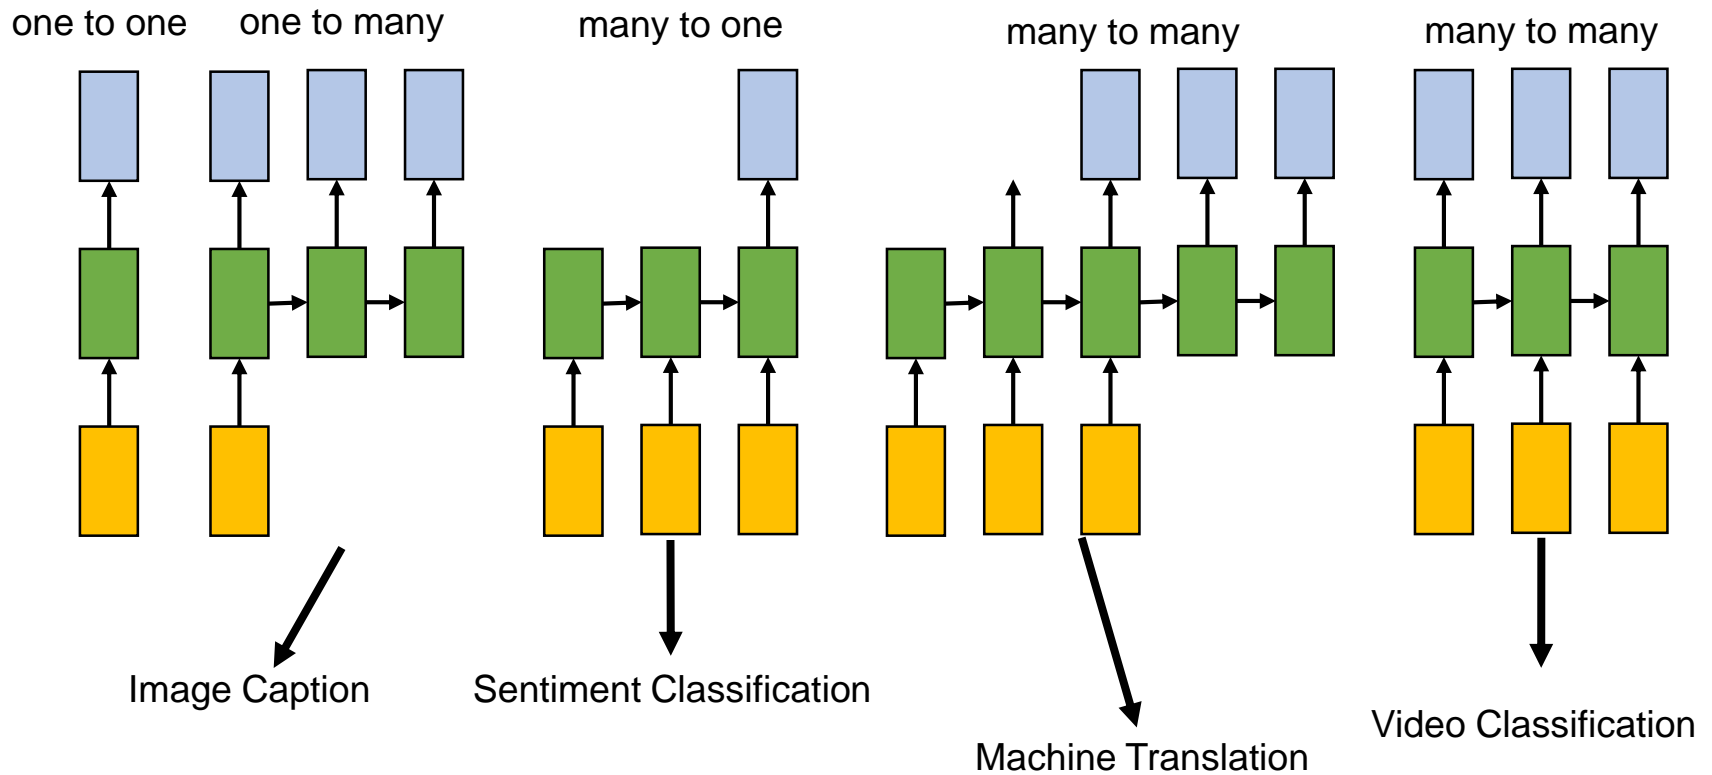
$$y_t = \text{softmax}(c + Vh_t)$$

b, c 为偏置向量

其它RNN模型：LSTM，GRU等。

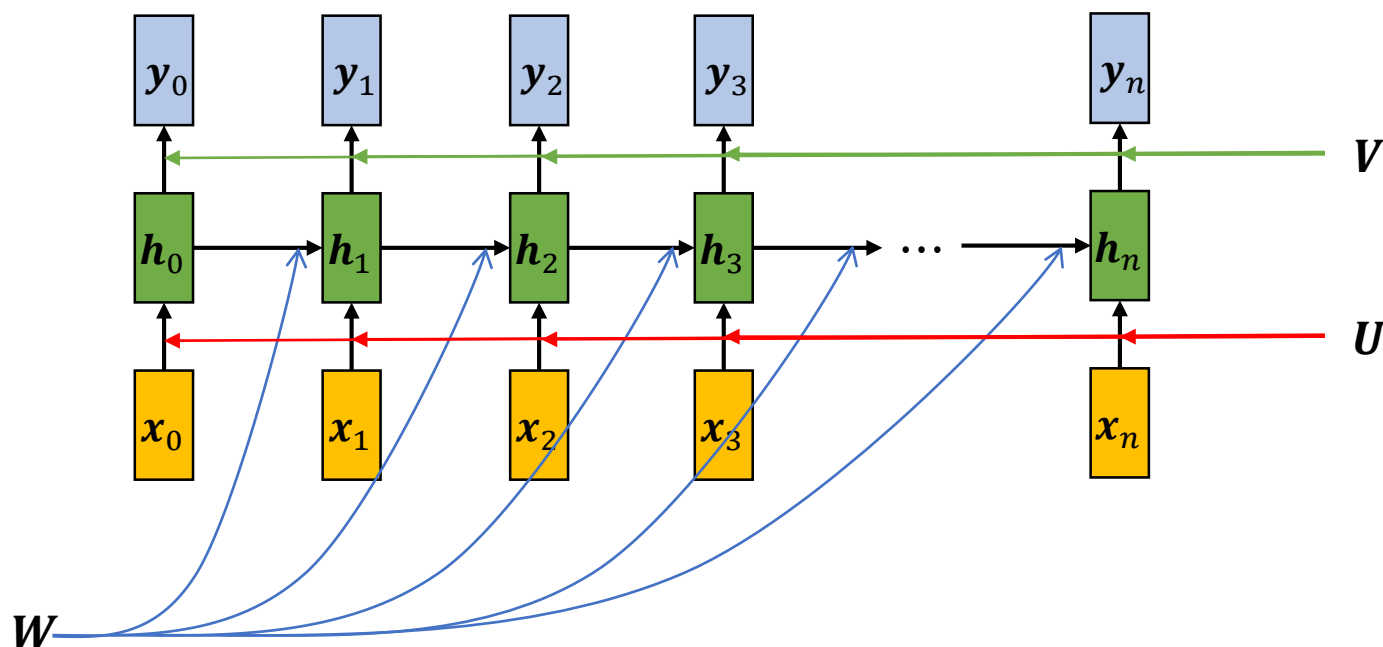
循环神经网络

- RNN按照输入输出可以分为以下四种。



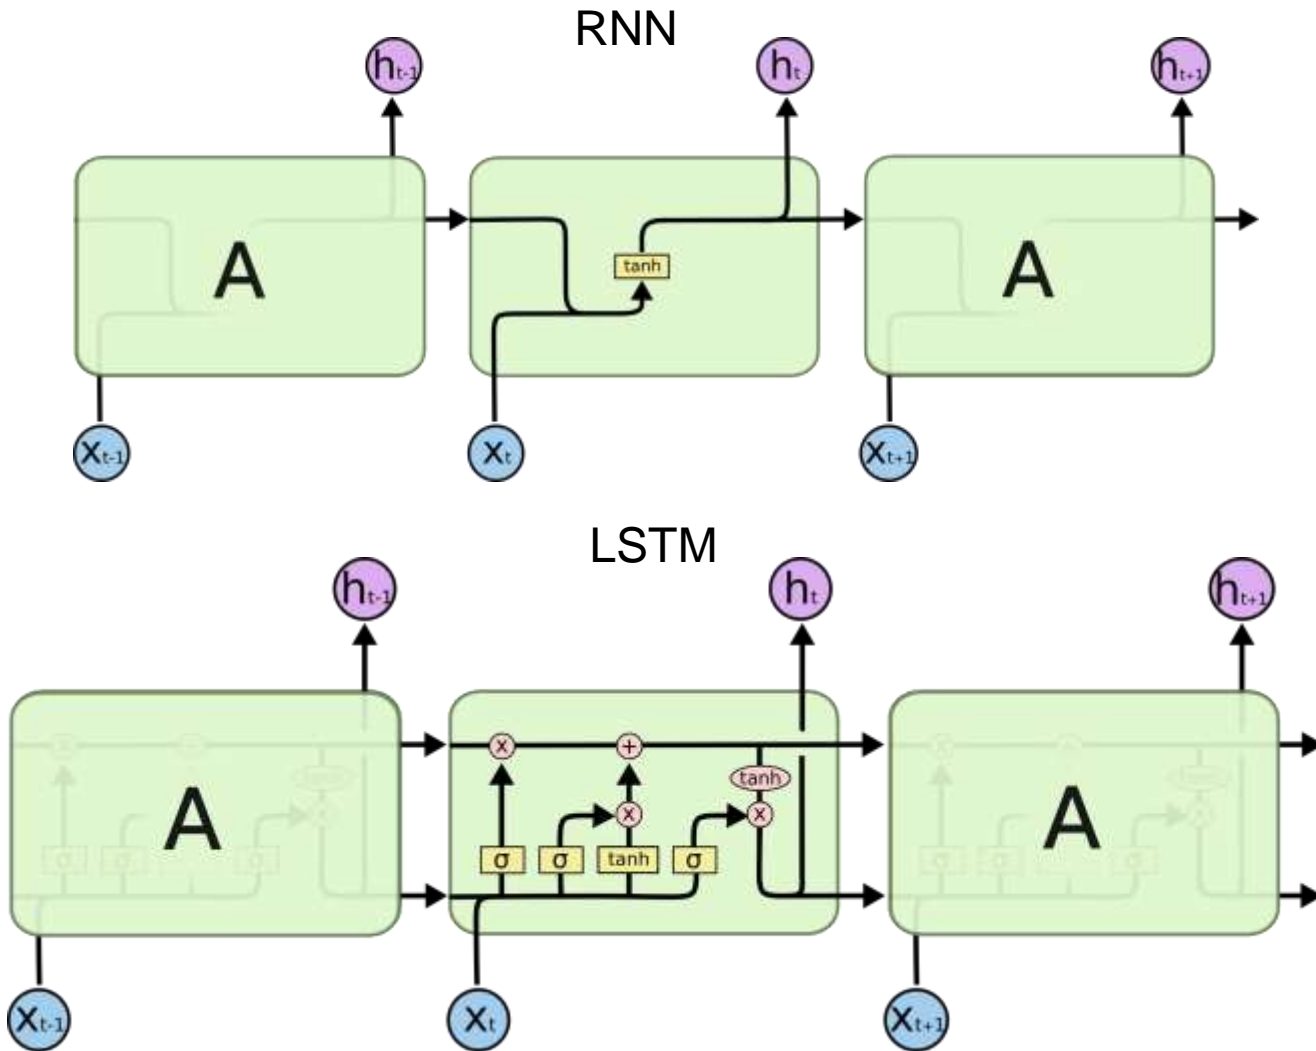
循环神经网络：参数共享

- RNN的一个特点是所有的隐层共享参数(W , U , V), 这样极大地缩小了参数空间。



Long short-term memory (LSTM)

更好地处理长程记忆



RNN诗歌创作

一声秋雁连天远, (*P*ZPPZ)

The twitter of a wild goose
comes from the distant horizon.

万里归帆隔水遥。 (*ZPPZZP)

The homebound ships are still ten
thousand miles away from the destination

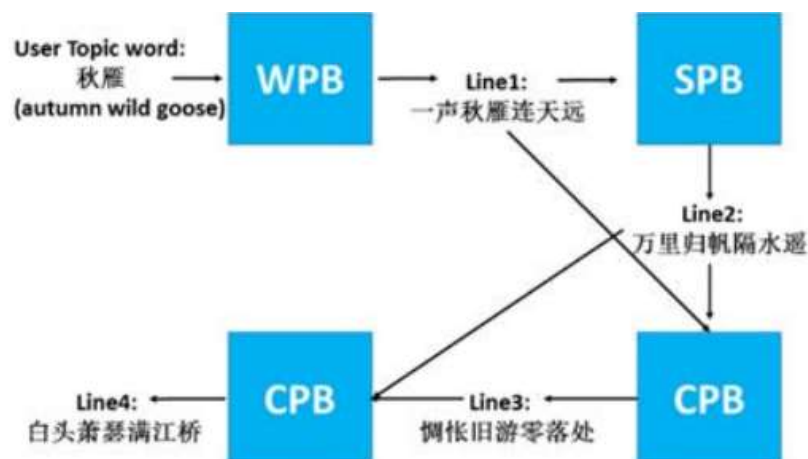
惆怅旧游零落处, (*Z*PPZZ)

I am so sad to be the place where I
said goodbye to my travelling companions.

白头萧瑟满江桥。 (*P*ZZPP)

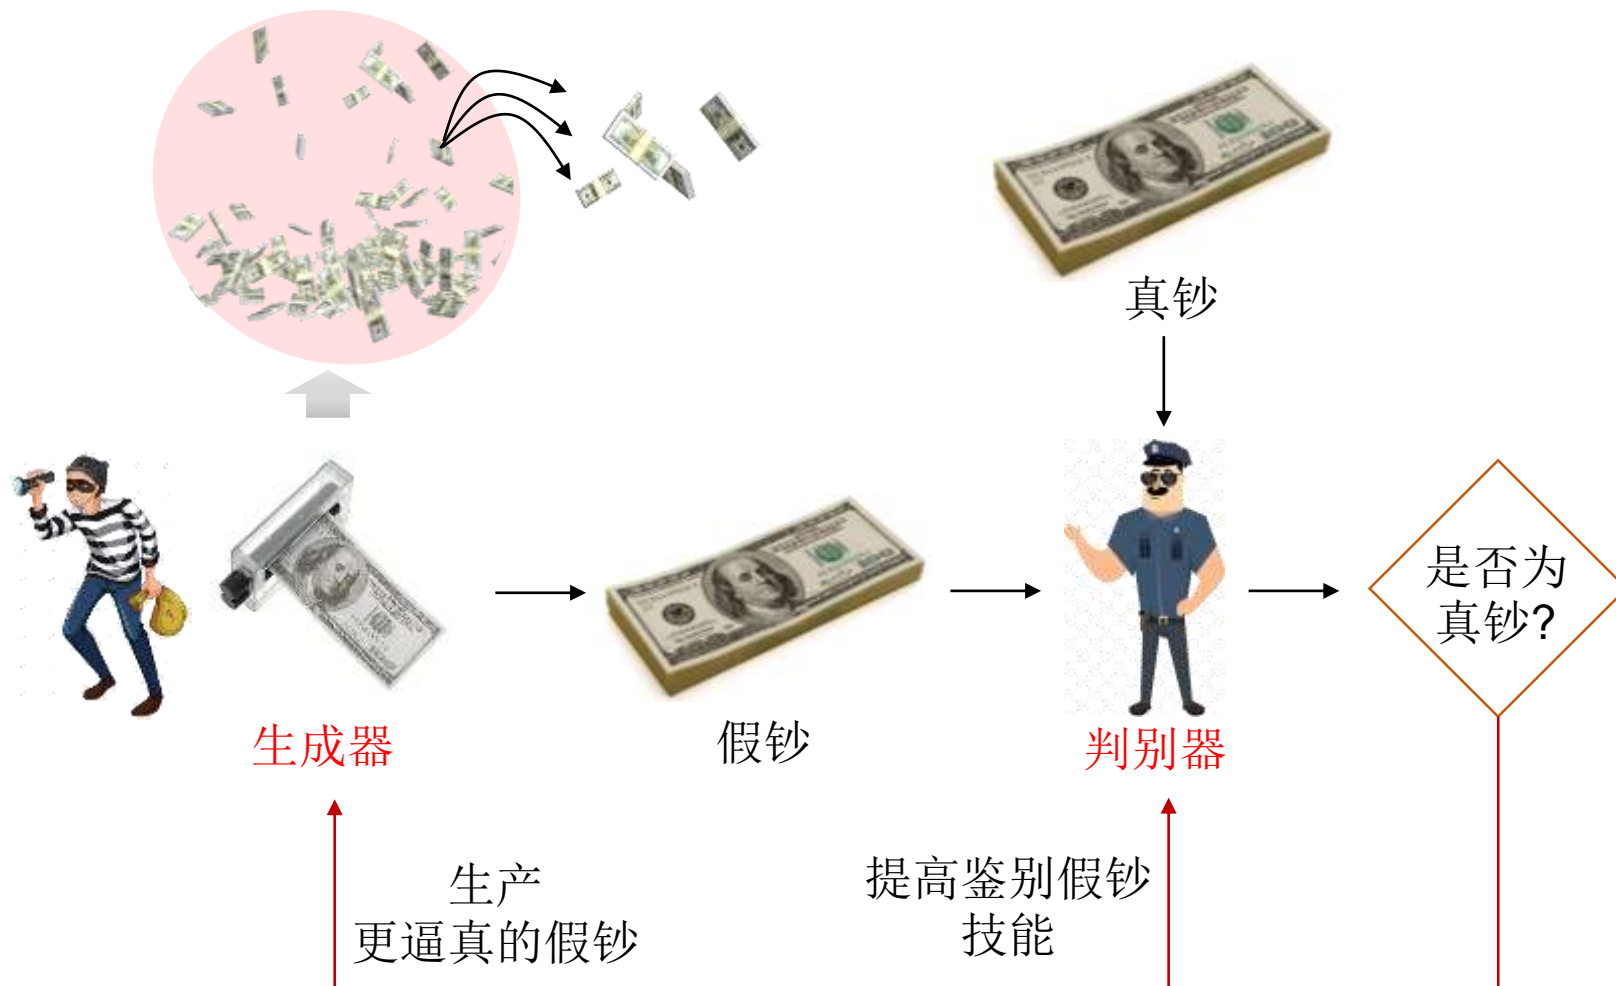
There is nothing here, but a gloomy
spectacle and the old me in the bridge.

X Yi, CCL, 2016

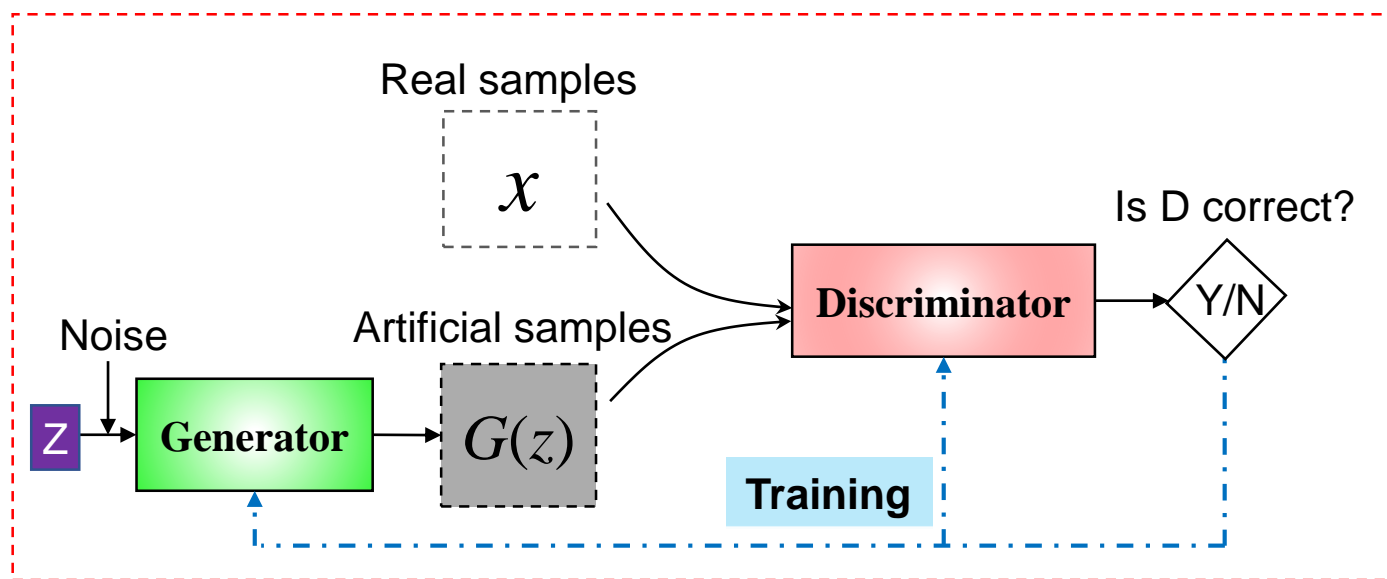


利用深度学习做分布估计： 对抗生成网络（Generative Adversarial Nets, GAN）

➤ 生成器与判别器的自我博弈



利用深度学习做分布估计： 对抗生成网络（Generative Adversarial Nets, GAN）



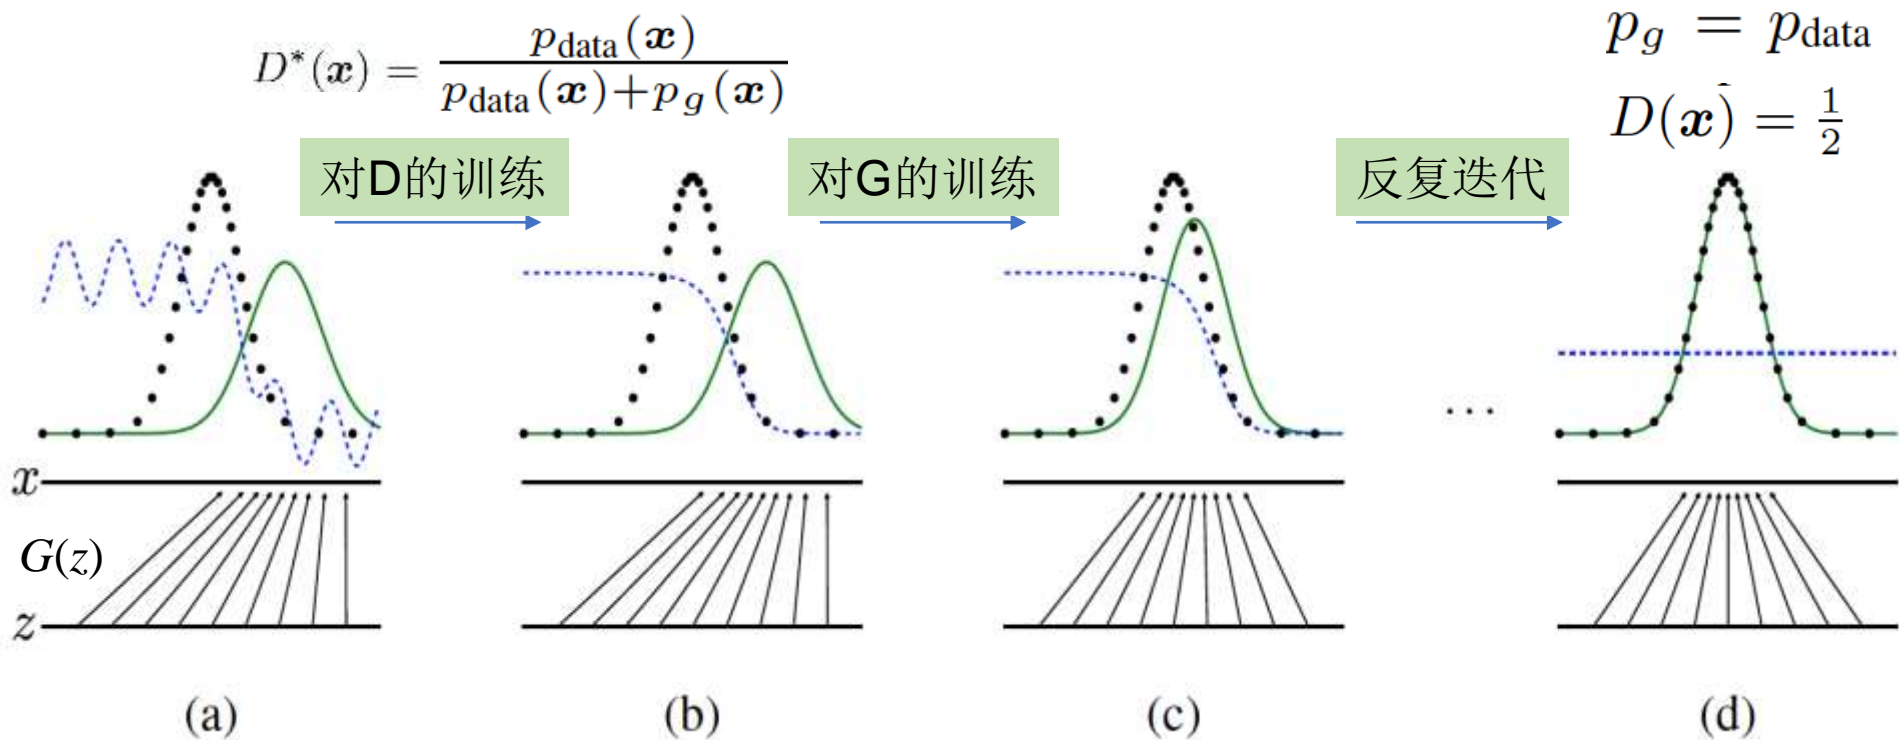
目标函数：

$$\min_G \max_D V(D, G) = \mathbb{E}_{\mathbf{x} \sim p_{\text{data}}(\mathbf{x})} [\log D(\mathbf{x})] + \mathbb{E}_{\mathbf{z} \sim p_{\mathbf{z}}(\mathbf{z})} [\log(1 - D(G(\mathbf{z})))]$$

- $\max D$ 使得分类器尽量准确的区分真实样本和生成样本，即最大化 $\log(D(x))$ 和 $\log(1-D(G(z)))$
- $\min G$ 使得生成器尽量骗过分类器，即 $\log(1-D(G(z)))$ 最小

生成对抗网络的训练过程示意

初始化的D和G



这里的 \mathbf{Z} 表示一个均匀分布, $G(\mathbf{z})$ 是从 \mathbf{Z} 到 \mathbf{X} 的函数映射

GAN算法流程

Algorithm 1 Minibatch stochastic gradient descent training of generative adversarial nets. The number of steps to apply to the discriminator, k , is a hyperparameter. We used $k = 1$, the least expensive option, in our experiments.

for number of training iterations **do**

for k steps **do**

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Sample minibatch of m examples $\{x^{(1)}, \dots, x^{(m)}\}$ from data generating distribution $p_{\text{data}}(x)$.
- Update the discriminator by ascending its stochastic gradient:

$$\nabla_{\theta_d} \frac{1}{m} \sum_{i=1}^m \left[\log D(x^{(i)}) + \log \left(1 - D(G(z^{(i)})) \right) \right].$$

end for

- Sample minibatch of m noise samples $\{z^{(1)}, \dots, z^{(m)}\}$ from noise prior $p_g(z)$.
- Update the generator by descending its stochastic gradient:


$$\nabla_{\theta_g} \frac{1}{m} \sum_{i=1}^m \log \left(1 - D(G(z^{(i)})) \right).$$

end for

The gradient-based updates can use any standard gradient-based learning rule. We used momentum in our experiments.

GAN应用 – 图像生成

A Brock, ICLR, 2018 – Big-GAN




Generator Structure

GAN应用 – 风格迁移

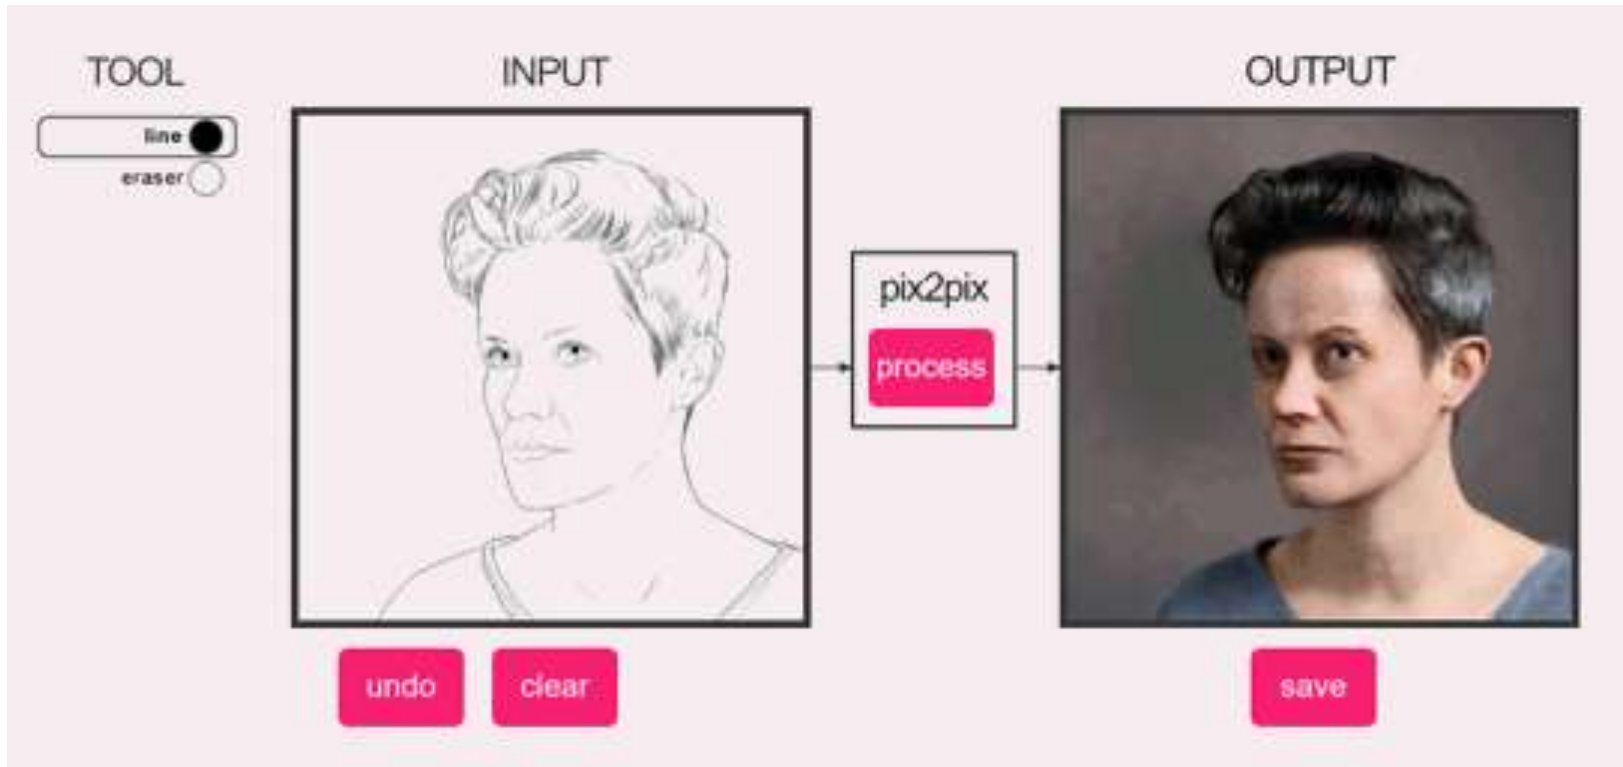


JY Zhu, CVPR, 2017 - cycleGAN



一个有趣的例子

Pix2pix – 图像翻译



甚至可以自己尝试：

<https://affinelayer.com/pixsrv/>

课外阅读：

- LeCun, Y., Bengio, Y. and Hinton, G. E.
Deep Learning
Nature, (2015), Vol. 521, pp 436-444
- Ian Goodfellow, Yoshua Bengio, Aaron Courville
Deep Learning
MIT press, 2016, <https://www.deeplearningbook.org>